Geautomatiseerde prijsvergelijking voor Belgische supermarktketens.

Een Proof of Concept-systeem voor de in Gent aanwezige supermarktketens, gebaseerd op openbaar toegankelijke data.

Aliaksandra Nemchynava.

Scriptie voorgedragen tot het bekomen van de graad van
Professionele bachelor in de toegepaste informatica

Promotor: Mevr. L. Vuyge
Co-promotor: Dhr. J. Pots
Academiejaar: 2025–2026
Eerste examenperiode

Departement IT en Digitale Innovatie .

HO GENT

Woord vooraf

Einde van de weg. Het laatste grote project achter de rug. En wat voor een project was het ook om mee te mogen afstuderen. Naast de vele frustraties heeft het mij ook ontzettend veel geleerd over scraping, asynchroon programmeren en prijzen in de winkel.
Ik wil hier mijn co-promotor Jens Pots bedanken voor zijn leiding en steun wanneer geen idee had wat een verdere stap moet zijn. Ik wil mijn promotor Leen Vuyge bedanken voor haar geduld, positieve geest en constructieve feedback. In het bijzonder wil ik Jozef, mijn verloofde, bedanken voor het vele leeswerk en suggesties, alsook vele tassen koffie.
De auteur is geen moedertaalspreker van het Nederlands. Voor taalkundige correcties en herformuleringen van de tekst werd gebruikgemaakt van een AI-gebaseerde taalassistent. De inhoud, structuur en conclusies van dit werk zijn volledig van de auteur zelf.

Samenvatting

De stijgende voedselprijzen in België leggen een groeiende financiële druk op studenten met een beperkt budget en beperkte mobiliteit. Bestaande prijsvergelijkingstools houden onvoldoende rekening met praktische beperkingen van winkelen, namelijk productnaam matching. Die tools baseren zich vooral op barcodevergelijking, waardoor kan de gebruiker niet altijd het product vinden en worden huismerken vaak buiten de scope gelaten. Daarnaast staan veel van deze diensten of hun extra functies achter een betaalmuur.

Dit onderzoek richt zich op het ontwerpen van een systeem dat consumenten, met name studenten in Vlaanderen, ondersteunt om weloverwogen beslissingen te kunnen nemen over hun boodschappen. De centrale onderzoeksvraag luidt: "Hoe kan een transparant en schaalbaar systeem worden ontworpen en ontwikkeld om automatisch supermarktprijzen in België te verzamelen, te matchen en te vergelijken, met gebruik van een semantisch matchingsysteem?"

Het voorgestelde prototype wordt ontwikkeld in Python en Django, waarbij gebruik wordt gemaakt van webscrapingstechnieken om prijsgegevens van Belgische supermarktwebsites te verzamelen. De gegevens worden opgeslagen in een PostgreSQL-database. Gebruikers kunnen een product opzoeken om de prijzen in verschillende winkels in een oogopslag vergelijken. Een andere mogelijkheid is om een boodschappenlijst in te voeren. Vervolgens wordt het meest kostefficiënte aankoopplan door het systeem berekend. De gegenereerde voorstellen worden geëvalueerd door hun besparingen te vergelijken met een aankoop van alle boodschappen in één winkel, op basis van vooraf gedefinieerde boodschappenlijsten. Hoewel het systeem duidelijk tijdsbesparend is voor de gebruiker, leiden enkel semantische matches op zich niet tot kostbesparingen.

Dit project draagt bij aan een realistisch en toegankelijk prijsvergelijkingssysteem gericht op studenten. Dit stelt studenten in staat bewuster en voordeliger te winkelen.

Inhoudsopgave

Lijst van figuren

Lijst van tabellen

Lijst van codefragmenten

1

Inleiding

De voedselprijzen in België zijn de afgelopen jaren aanzienlijk gestegen, wat een groeiende financiële druk legt op studenten en andere budgetbewuste consumenten. Hoewel er verschillende prijsvergelijkingstools voor supermarkten bestaan, richten deze zich over het algemeen op het presenteren van de laagste prijzen zonder rekening te houden met praktische beperkingen, zoals de afstand die een consument bereid is af te leggen of het aantal winkels dat hij of zij redelijkerwijs kan bezoeken. Hierdoor bieden deze tools theoretisch optimale oplossingen die in de praktijk niet haalbaar zijn, vooral voor studenten met beperkte mobiliteit en een strak schema.

1.1. Probleemstelling

Studenten ondervinden vaak uitdagingen bij het vinden van de meest kostenefficiënte winkelopties. Beperkte budgetten, gecombineerd met tijd- en reisbeperkingen, bemoeilijken efficiënte prijsvergelijkingen tussen verschillende supermarkten. Bestaande tools houden zelden rekening met deze beperkingen, waardoor er een kloof ontstaat tussen beschikbare prijsinformatie en bruikbare, gebruikersgerichte inzichten. Dit onderzoek pakt deze kloof aan door zich te richten op de ontwikkeling van een systeem dat afgestemd is op de behoeften van studenten met een beperkt budget in Gent.

1.2. Onderzoeksvraag

Om een dergelijk systeem te ontwikkelen, moet de volgende hoofdonderzoeksvraag worden beantwoord: Hoe kan een transparant en schaalbaar systeem worden ontworpen en ontwikkeld om automatisch supermarktprijzen in België te verzamelen, te matchen en te vergelijken, met gebruik van een semantisch matchingsysteem?

1.3. Deelvragen

Verder moet onderzoek worden gedaan naar de programmatische en architecturale details van de beoogde oplossing en de succesfactoren ervan. Meer specifiek:

- Hoe kunnen supermarktprijsgegevens automatisch worden verzameld en gestructureerd?
- Welke benaderingen kunnen worden gebruikt om algemene productnamen te matchen en zo nauwkeurige vergelijkingen te maken?
- Hoe kan de systeemarchitectuur worden ontworpen om schaalbaarheid en transparantie van de data te ondersteunen?
- Aan welke criteria moet het prototype voldoen om als een geldig proof-of-concept te worden beschouwd?

Om deze vragen te beantwoorden en het onderzoek te sturen, is inzicht vereist in de doelgroep en de probleemcontext. Meer specifiek:

- Welke tools voor prijsvergelijking zijn er in België beschikbaar en welke tekortkomingen hebben ze voor studenten?
- Welke technische en praktische uitdagingen zijn er bij het verzamelen van prijsgegevens van Belgische supermarkten?

1.4. Onderzoeksdoelstelling

Het resultaat van dit onderzoek is een prototype, geïmplementeerd met Python en Django, dat prijsgegevens verzamelt via webscraping van Belgische supermarktwebsites. Gebruikers van dit prototype kunnen producten en een algemene boodschappenlijst invoeren. Het systeem berekent vervolgens de meest kostenefficiënte combinatie van winkels. Het systeem wordt geëvalueerd met behulp van een vooraf gedefinieerde standaardboodschappenlijst voor studenten om de totale kosten van een aankoop in één winkel te vergelijken met de door het systeem gegenereerde, geoptimaliseerde aanbeveling voor meerdere winkels.
Dit onderzoek draagt bij aan de ontwikkeling van realistische en toegankelijke tools voor supermarktprijsvergelijking die technische efficiëntie combineren met consumentgerichte beperkingen. Door zich te richten op de behoeften van studenten, beoogt het systeem de prijstransparantie te vergroten en weloverwogen, budgetbewuste winkelbeslissingen te ondersteunen. Het biedt praktische inzichten die toekomstige consumentgerichte toepassingen kunnen inspireren.

1.5. Opzet van deze bachelorproef

De rest van deze bachelorproef is als volgt opgebouwd:

In Hoofdstuk 2 wordt een overzicht gegeven van de stand van zaken binnen het onderzoeksdomein, op basis van een literatuurstudie.
In Hoofdstuk 3 wordt de methodologie toegelicht en worden de gebruikte onderzoekstechnieken besproken om een antwoord te kunnen formuleren op de onderzoeksvragen.
In Hoofdstuk 4 wordt het werk beschreven dat werd verricht om het project op te bouwen, met een focus op de gekozen architectuur, de gebruikte technologieën en de implementatie van de belangrijkste systeemcomponenten.
In Hoofdstuk 5 wordt de applicatie onderworpen aan een reeks realistische gebruiksscenario's. Deze testen hebben tot doel om de correctheid van de resultaten, de stabiliteit van het systeem en de bruikbaarheid van de applicatie in een realistische context te evalueren.
In Hoofdstuk 6 worden de beperkingen van het huidige systeem besproken en worden mogelijke uitbreidingen en verbeteringen voor toekomstig werk voorgesteld.
In Hoofdstuk 7, tenslotte, wordt de conclusie gegeven en een antwoord geformuleerd op de onderzoeksvraag.

2

Stand van zaken

In het vorige hoofdstuk is de probleemstelling geschetst: studenten in Gent hebben behoefte aan een prijsvergelijkingssysteem dat rekening houdt met praktische beperkingen zoals reisafstand en een beperkt budget. Dit hoofdstuk plaatst dat probleem in een bredere context door de stand van zaken in het onderzoeksdomein te beschrijven. Digitale prijsvergelijkingstools en geautomatiseerde dataverzameling worden steeds belangrijker in de voedselretail. Dit onderzoek situeert zich op het kruispunt van drie relevante domeinen: webgebaseerde dataverzameling, productnormalisatie- en prijsvergelijkingssystemen voor consumenten.

2.1. Context: voedselprijzen en studentendruk

Recente economische indicatoren van België wijzen op aanhoudende prijsdruk op voeding. Volgens het CPI-rapport van Statbel blijven de algemene en kerninflatie gedurende 2024-2025 hoog, met een kerninflatie van meer dan 2% in oktober 2025(Statbel, 2025a, 2025b). Onafhankelijke tracking door Testaankoop/Testachats meldt eveneens een supermarktspecifieke inflatie van ongeveer 4% in 2025(Testaankoop, 2025a, 2025b). Bredere macro-economische analyses(*OECD Economic Surveys: Belgium 2024*, 2024) tonen de gedetailleerde impact van inflatie aan en bevestigen de prijsdruk op consumenten. Samen onderbouwen deze bronnen de relevantie van het probleem voor prijsgevoelige groepen zoals studenten.

2.2. Bestaande oplossingen

Er zijn verschillende specifieke Belgische tools beschikbaar om consumenten te helpen supermarktprijzen te vergelijken en betere producten te selecteren, zoals PingPrice (PingPrice, 2024) en G4U (G4U, 2025). Beide apps hebben echter hun beperkingen. PingPrice vergelijkt producten met behulp van barcodes, waardoor het geen effectieve vergelijking kan maken tussen huismerkproducten of gene-

rieke producten die geen gestandaardiseerde identificatiecodes hebben. Hierdoor worden veel relevante artikelen uitgesloten van vergelijkingen.
G4U biedt daarentegen uitgebreide product- en promotie-informatie, maar werkt als een betaalde dienst, waardoor de toegankelijkheid beperkt is voor studenten die al met financiële beperkingen kampen. Daarom is er behoefte aan een gratis en transparant alternatief waarmee gebruikers generieke productcategorieën kunnen vergelijken in plaats van barcodes.
In Tabel 2.1 worden de belangrijkste kenmerken visueel representeert.

2.3. Supermarktdata: webscraping als praktische pijplijn

Omdat Belgische retailers zelden API's voor product-/prijsfeeds openbaar maken, is webscraping een pragmatische manier om gestructureerde prijsgegevens van openbare pagina's te verkrijgen. Hoewel (Logos et al., 2023) en (Brown et al., 2024) een ethische en methodologische benadering van webscraping beschrijven, stellen ze geen specifieke technische implementatie voor voor gevallen waarin openbare API's niet beschikbaar zijn.
Voortbouwend op hun aanbevelingen wordt in dit onderzoek het volgende proces voorgesteld: HTML-opvraging, parsing van de content, headless browser voor JavaScript-afhankelijke content en opslag van de prijsgegevens. Deze aanpak voor de specifieke Belgische markt is geïnspireerd op het (Ken Van Loon, 2018) artikel van Statbel.

2.4. Juridische en ethische overwegingen voor scraping

Scraping moet voldoen aan de servicevoorwaarden (ToS), intellectuele eigendomsrechten en beperkingen op het gebied van gegevensbescherming. Vergelijkende analyses van de ToS van websites laten zien dat veel platforms "robots/scrapers" expliciet reguleren, waardoor onderzoekers noodzakelijkheid, proportionaliteit en nalevingsmechanismen moeten afwegen (Fiesler et al., 2020). Recente overzichten stellen concrete checklists voor over legaliteit, ethiek en institutionele beoordeling: bijvoorbeeld het documenteren van het doel, snelheidslimieten, opslag en datadeling (Brown et al., 2024; Logos et al., 2023). Deze kaders vormen de basis voor het beheer van het prototype.

2.5. Productmatching tussen retailers

Prijsvergelijking vereist het matchen van 'hetzelfde' artikel in alle winkels, ondanks verschillen in naamgeving/verpakkingsgrootte. Bestaande literatuur ondersteunt een tweefasenaanpak: 1. exacte identificatiegegevens (bijv. EAN/GTIN) indien beschikbaar; 2. benaderende/semantische matching met behulp van fuzzy similarity (Levenshtein/TF-IDF/cosinus) of ML-embeddings voor detectie van bijna-duplicaten (Kerek, 2020; Ning et al., 2022). Deze methoden koppelen de door de gebruiker op-

Tabel 2.1: Functionele vergelijking tussen bestaande tools en het voorgestelde prototype

Kenmerk	PingPrice	G4U	Prototype
Naam matching	-	?	+
Transparantie	-	-	+
Beperkingen (afstand/aantal winkels)	-	-	+
Gratis	+	-	+

+ = ondersteund, - = niet ondersteund, ? = gedeeltelijk/onduidelijk

gegeven productnaam direct aan het specifieke productaanbod van de winkel.

2.6. Beslissingsondersteuning, vertrouwen en beperkingen in boodschappenapps

Vertrouwen is een cruciale factor die de bereidheid van gebruikers om digitale boodschappentools te gebruiken beïnvloedt. (Chakraborty et al., 2024) benadrukt het belang van geloofwaardigheid van informatie, duidelijkheid en kwaliteit van de interactie om het vertrouwen van gebruikers in online boodschappenomgevingen te vergroten. Voortbouwend op dit perspectief benadrukt (DeZao, 2024) het vertrouwen in AI-gestuurde systemen. Door hun gegevensbronnen en tijdstempels te tonen, worden deze systemen transparanter en daardoor ook als betrouwbaarder en eerlijker ervaren door gebruikers. Bovendien beïnvloeden praktische beperkingen, zoals reisafstand en de mogelijkheid om slechts een bepaald aantal winkels te bezoeken, het nut van dergelijke tools. Integratie van deze beperkingen breidt de criteria voor beslissingsondersteuning verder uit en verbetert deze.
Samenvattend, de literatuur ondersteunt een pijplijn die webscraping, reproduceerbare matching (EAN-first + fuzzy/ML fallback) en transparante interfaces combineert, geëvalueerd op precisie/recall voor matches en realistische, op de student gerichte beperkingen (bijv. afstand, maximaal aantal winkels) voor kostenresultaten.

3

Methodologie

Dit proefschrift richt zich op het ontwerp en de implementatie van een functioneel prototype dat automatisch supermarktprijzen in Gent verzamelt, vergelijkt en matcht.

3.1. Proof of concept

De proof of concept opbouw bestaat uit vier opeenvolgende fasen: systeemontwerp, dataverzameling, dataverwerking en evaluatie.

3.1.1. Systeemontwerp

In de eerste fase werden de architectuur en datastroom van het systeem gedefinieerd met als doel modulariteit, schaalbaarheid en transparantie te garanderen.Het systeem is opgebouwd als een modulaire, event-gedreven pipeline bestaande uit vier lagen. De eerste laag is de scrapingslaag: product- en prijsinformatie wordt verzameld van de websites. De tweede laag is de transportlaag, verantwoordelijk voor publicatie van de ruwe data komende uit de scrapingslaag in Kafka. De derde laag is de verwerkingslaag, daar een Kafka-consumer verwerkt, normaliseert, matcht producten, en slaat de resultaten op in een PostgreSQL-database. De vierde laag is de presentatielaag: een Django-gebaseerde webinterface dat het mogelijk maakt om boodschappenlijsten of producten in te voeren en zoekt de best passende producten met de laagste prijzen.

3.1.2. Dataverzameling

De dataverzamelingsfase richt zich op het verzamelen van dagelijkse product- en prijsinformatie van geselecteerde Gentse supermarkten. Dit wordt uitgevoerd met behulp van webscrapingtechnieken, geïmplementeerd via Scrapy-spiders. Scrapy wordt gebruikt om HTTP-verzoeken te versturen en de onbewerkte HTML-inhoud

van webpagina's op te halen, waardoor toegang wordt verkregen tot publiek beschikbare informatie zonder een volledige browseromgeving.
De spiders extraheren relevante gegevens zoals productnamen, verpakkingsformaten, prijzen en merklabels door specifieke HTML-elementen te parsen. Voor websites die gebruikmaken van JavaScript-gedreven dynamische inhoud wordt een browser-emulator ingezet, zodat pagina's eerst volledig kunnen laden voordat ze verwerkt worden.
In plaats van de gegevens onmiddellijk op te slaan of te verwerken, worden alle gescrapete productrecords als ruwe JSON-objecten gepubliceerd naar een Kafka-topic. Hierdoor wordt de dataverzameling losgekoppeld van de daaropvolgende verwerkingsstappen, wat de schaalbaarheid en fouttolerantie van het systeem verhoogt. Naast de productinformatie zelf wordt ook metadata zoals tijdstip en bronwinkel meegestuurd, waardoor transparantie en reproduceerbaarheid worden gegarandeerd.

3.1.3. Dataverwerking en productmatching

De dataverwerking gebeurt asynchroon in een aparte module die berichten uit Kafka consumeert. Omdat supermarkten verschillende productnamen en -formaten gebruiken, moeten de verzamelde gegevens worden voorbewerkt voordat ze kunnen worden vergeleken. Deze fase bestaat uit een aantal stappen: data cleaning, normalisatie en productmatching. De dataopschoningsstap omvat het verwijderen van duplicaten en eenheidsnormalisatie (bijvoorbeeld prijs per kg of per liter).
De matchingstap implementeert string-gelijkaardigheidssalgoritmen, zoals Levehnstein-afstand en regex-matching, om gelijkwaardige producten in verschillende winkels te matchen. De filterstap slaat de dichtstbijzijnde productmatches op om nauwkeurigheid in vergelijkingen te garanderen. Het resultaat van deze fase is een uniforme dataset waarin identieke of vergelijkbare producten uit verschillende winkels direct kunnen worden vergeleken.

3.1.4. Interfaceontwikkeling en integratie

De tool cobineert alle componenten in één Django-gebaseerde webapplicatie. Daarnast wordt er een vergelijking module binnen deze applicatie uitgewerkt die berekent voor een ingevoerd boodschappenlijstje de kostprijs als alle producten in één winkel worden gekocht en de minimale totale prijs bij een optimale winkelcombinatie, rekening houdend met maximale reisafstand en maximaal aantal winkels.

3.1.5. Evaluatie

De evaluatiefase beoordeelt de praktische bruikbaarheid van het systeem, met behulp van vooraf gedefinieerde winkelwagentjes voor studenten die realistische aankoopscenario's simuleren. Elk winkelwagentje wordt vanuit twee perspectieven geanalyseerd: winkelen in één winkel (alle artikelen in één supermarkt kopen) en ge-

optimaliseerd winkelen in meerdere winkels (alle artikelen kopen op basis van de aanbevelingen van het systeem).
Op basis van deze resultaten kan het prototype worden beschouwd als een succesvol proof-of-concept als het in staat is om kostenbesparingen te realiseren voor Gentse studenten met verschillende criteria, terwijl de transparantie in het besluitvormingsproces behouden blijft.

4

Prototype

Dit project werd initieel opgezet als een proof-of-concept om de haalbaarheid van een automatische prijsvergelijker te evalueren. Tijdens de implementatie evolueerde het prototype echter naar een robuust en modulair systeem, met een duidelijke scheiding van verantwoordelijkheden en ondersteuning voor schaalbare dataverwerking. De webscrapingapplicatie is ontworpen met het oog op bruikbaarheid voor een breed publiek — met name studenten — dat niet beschikt over uitgebreide kennis van programmeren of softwareontwikkeling. De gebruiker heeft enkel een internetverbinding nodig en hoeft geen technische configuraties uit te voeren om het systeem te gebruiken.
Hoewel het project in zijn huidige vorm niet als volledig uitgerolde productieapplicatie kan worden beschouwd, biedt het wel een realistisch en werkbaar kader om inzicht te krijgen in moderne webscrapingarchitecturen. Het gebruik van Docker en een testomgeving maakt het mogelijk om het systeem lokaal te runnen en te experimenteren met de verschillende componenten, wat bijdraagt aan het educatieve karakter van het prototype.
Deze doelstelling impliceert dat de technische complexiteit van web scraping volledig wordt afgeschermd van de eindgebruiker. Interacties met het systeem verlopen via een eenvoudige en intuïtieve gebruikersinterface, terwijl alle onderliggende processen — zoals het ophalen van webpagina's, het verwerken en normaliseren van data, het omgaan met anti-scrapingmechanismen en de opslag van gegevens — volledig achter de schermen worden afgehandeld.
Het prototype ondersteunt:

- gebruikersgestuurde productzoekopdrachten
- automatische prijsvergelijking over meerdere supermarkten
- een slimme winkelmandfunctionaliteit

- achtergrondverversing van prijsdata
- fouttolerante scraping van heterogene databronnen

Het prototype fungeert hiermee als een abstraherende laag tussen de gebruiker en de onderliggende scrapingsinfrastructuur. Hoewel het systeem niet perfect is en nog verschillende beperkingen kent, slaagt het er wel in om de kernideeën en doelstellingen van een automatische prijsvergelijker duidelijk te demonstreren. Het project toont aan hoe een dergelijke toepassing kan worden opgebouwd, welke technische uitdagingen daarbij komen kijken en hoe deze op een gestructureerde manier kunnen worden aangepakt.

4.1. Keuze van programmeertaal en frameworks

De keuze van programmeertaal en bijhorende frameworks vormt een essentiële ontwerpbeslissing binnen dit prototype. Literatuur toont aan dat verschillende programmeertalen geschikt zijn voor web scraping, waaronder Python, JavaScript en C#. Op basis van vergelijkende studies en best practices (Data Journal, 2024; Majebi, 2025) is Python gekozen als primaire programmeertaal voor het prototype.
Deze keuze voor Python kan gemotiveerd worden door meerdere factoren. Ten eerste beschikt Python over een uitgebreid ecosysteem van bibliotheken die specifiek ontworpen zijn voor interactie met de inhoud van websites, zoals *Requests*, *BeautifulSoup*, *Scrapy* en *Playwright*. Hierdoor kan snel en efficiënt worden ingespeeld op uiteenlopende scrapingsuitdagingen, variërend van eenvoudige HTML-pagina's tot complexe, dynamisch gegenereerde webinhoud. Ten tweede is Python relatief eenvoudig aan te leren, wat het bijzonder geschikt maakt voor beginnende ontwikkelaars en studenten. De leesbaarheid van de syntaxis en de grote hoeveelheid beschikbare documentatie en voorbeelden verlagen de instapdrempel aanzienlijk. Dit sluit aan bij de doelstelling van dit prototype, namelijk het ontwikkelen van een systeem dat toegankelijk is voor gebruikers zonder diepgaande programmeerkennis. Tot slot biedt Python voldoende mogelijkheden voor toekomstige uitbreidingen, zoals grootschalige dataverwerking, data-analyse en integratie van machine learning technieken. Hierdoor is Python niet alleen geschikt voor het huidige prototype, maar ook toekomstbestendig.
Binnen het Python-ecosysteem bestaan meerdere bibliotheken voor web scraping. Na een vergelijking werd gekozen voor *Scrapy* als centraal scrapingsframework. Deze keuze kan onderbouwd worden door het werk van (Eyzenakh et al., 2021), waarin verschillende scrapingsoplossingen zijn vergeleken op vlak van performantie, schaalbaarheid en architecturale opbouw. Scrapy onderscheidt zich van eenvoudigere oplossingen zoals *Requests* en *BeautifulSoup* door zijn asynchrone en event-gedreven architectuur. Dit maakt het mogelijk om meerdere webpagina's gelijktijdig te verwerken, wat resulteert in betere prestaties en efficiënter gebruik van systeembronnen. Daarnaast voorziet Scrapy ingebouwde ondersteuning voor

request scheduling, foutafhandeling, throttling en uitbreidbare pipelines voor dataverwerking. Een bijkomend voordeel van Scrapy is de duidelijke scheiding tussen verschillende verantwoordelijkheden, zoals het ophalen van data, het parsen van responses en het verwerken van resultaten. Deze modulaire opbouw sluit nauw aan bij de architecturale principes die in de literatuur worden beschreven en verhoogt de onderhoudbaarheid van het systeem.
Hoewel Scrapy krachtig is voor het verwerken van statische HTML-pagina's, volstaat het niet in alle situaties. Steeds meer websites maken gebruik van JavaScript om inhoud dynamisch te genereren. Om deze pagina's correct te kunnen verwerken, werd *Playwright* geïntegreerd in het scrapingsproces. Playwright maakt het mogelijk om een echte browseromgeving te simuleren en JavaScript-code uit te voeren alvorens de HTML wordt geëxtraheerd. Hierdoor kunnen ook websites met complexe client-side logica succesvol gescrapet worden. De combinatie van Scrapy en Playwright zorgt voor een flexibele aanpak waarbij per website de meest geschikte scrapingstrategie kan worden toegepast.
Om de verschillende lagen binnen het systeem van elkaar te ontkoppelen, werd gekozen voor Apache Kafka als verbindende component tussen de scrapingslaag en verdere verwerking van data. Kafka fungeert hierbij als een message broker die ruwe scrapingsresultaten doorstuurt naar volgende verwerkingsstappen. De keuze voor Kafka is geïnspireerd door moderne, event-gedreven architecturen zoals beschreven in (Sibiryakov, 2015). Door gebruik te maken van een message broker wordt de afhankelijkheid tussen scraping en verwerking verminderd. Dit verhoogt de schaalbaarheid en fouttolerantie van het systeem en maakt het mogelijk om data opnieuw te verwerken zonder de scrapingsfase te herhalen. Hoewel Kafka in dit prototype niet noodzakelijk op industriële schaal wordt ingezet, biedt het conceptueel een duidelijke meerwaarde en vormt het een solide basis voor toekomstige uitbreidingen.
Voor de backend van het prototype werd gekozen voor het Django-framework. Django sluit naadloos aan bij Python en biedt uitgebreide ondersteuning voor webapplicaties, databankintegratie en gebruikersinteractie. Een belangrijk voordeel van Django is de eenvoudige koppeling met Python-gebaseerde scrapingscomponenten. Hierdoor kunnen scrapingsprocessen, dataverwerking en gebruikersinterface binnen één technologisch ecosysteem worden geïntegreerd. Daarnaast voorziet Django standaardfunctionaliteiten zoals ORM (Object-Relational Mapping), authenticatie en administratie, wat de ontwikkeltijd aanzienlijk verkort.
Om de reproduceerbaarheid en consistentie van het systeem op verschillende machines te garanderen, werd gebruikgemaakt van Docker. Docker maakt het mogelijk om de volledige applicatie, inclusief afhankelijkheden, configuraties en services, te verpakken in containers. Hierdoor kan het prototype zonder bijkomende installatieproblemen uitgevoerd worden op verschillende systemen, wat zowel de ontwikkeling als de evaluatie vereenvoudigt.

De combinatie van Python, Scrapy, Kafka, Django en Docker resulteert in een coherente en uitbreidbare architectuur waarin elke technologie een duidelijk afgebakende rol vervult.

4.2. Klassieke web scraping pijplijn

De structuur van web scraping systemen wordt in de literatuur vaak beschreven als een opeenvolging van afzonderlijke verwerkingsstappen. (Laender et al., 2002) beschrijft web data extractie als een pijplijn bestaande uit meerdere logisch gescheiden fasen: selectie van databronnen, extractie van ruwe data, transformatie en normalisatie, integratie en opslag.
Deze architecturale scheiding verhoogt de onderhoudbaarheid van het systeem en maakt hergebruik en schaalbaarheid mogelijk. Het prototype volgt deze pijplijnstructuur expliciet. Op basis van de overleg met de co-promotor en de besproken state-of-the-art werd een modulaire architectuur voorgesteld. Deze architectuur is weergegeven in Figuur 4.1.

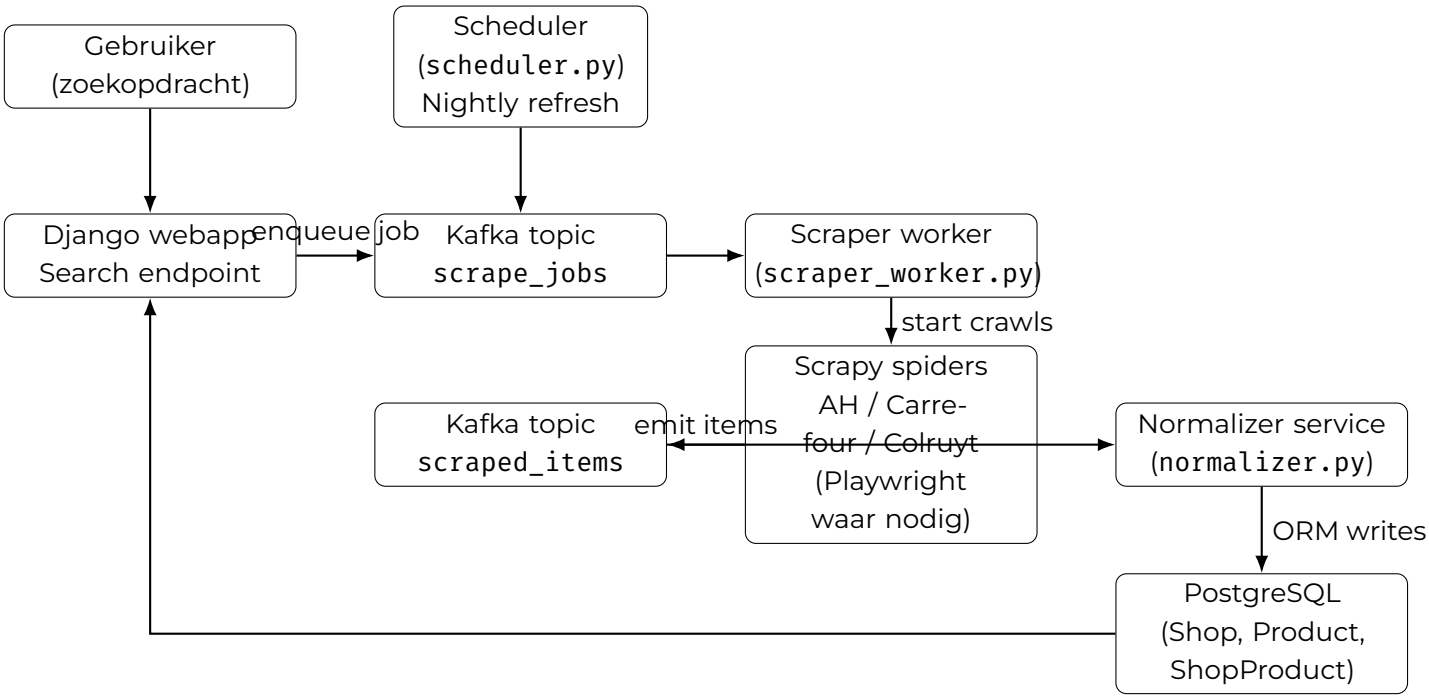

Figuur 4.1: Event-driven scraping pipeline: Django publiceert scrape-jobs naar Kafka; de scraper worker voert spiders uit; resultaten worden genormaliseerd en opgeslagen in de database.

De architectuur van het project bestaat uit vijf hoofdlagen:

1. Gebruikersinterface (Django)
2. Scrapinglaag (Scrapy spiders)
3. Ruwe datalaag (Kafka topics)

4. Transformatielaag (Normalizer)
5. Persistente databank (PostgreSQL)

Figuur 4.2 toont een alternatief visueel overzicht van dezelfde lagen.

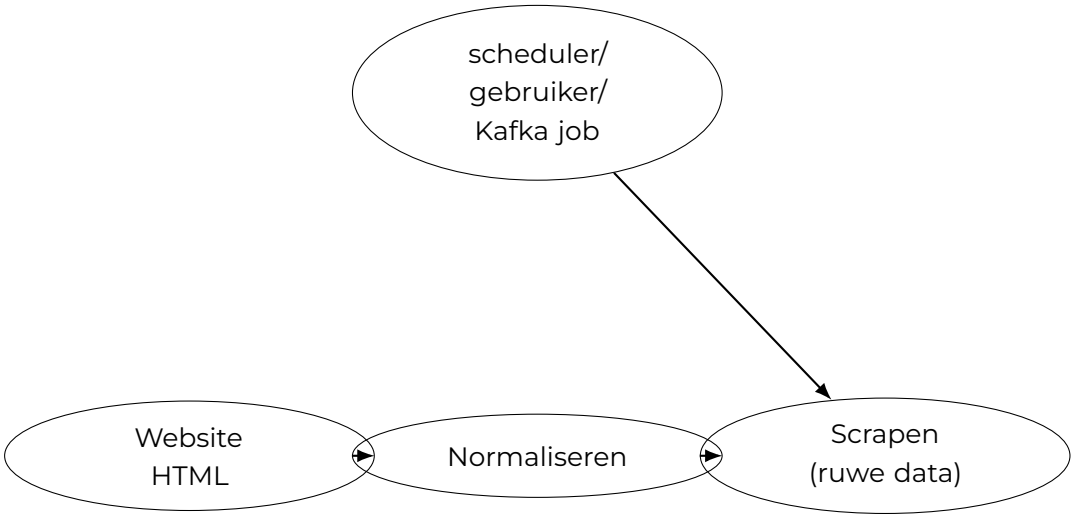

Figuur 4.2: Overzicht van de voorgestelde prototype-architectuur

4.3. Gebruikersinterface

De gebruikersinterface vormt het enige directe contactpunt tussen de gebruiker en het systeem. Via deze interface kan de gebruiker producten opzoeken of een lijst van producten invoeren die vergeleken moeten worden over meerdere supermarkten. De gebruiker heeft geen zicht op, noch controle over, de onderliggende scraping- en verwerkingslogica; deze wordt volledig door het systeem afgehandeld.
De implementatie van de gebruikersinterface is gebaseerd op het Django-framework, dat fungeert als centrale coördinatielaag tussen de frontend, de databank en de asynchrone scraping-infrastructuur.

4.3.1. Rol van Django binnen het systeem

Binnen dit project vervult Django een dubbele rol. Enerzijds verzorgt het framework de presentatie van gegevens via HTML-pagina's en API-endpoints, anderzijds fungeert het als orkestrator die scraping-opdrachten initieert en de levenscyclus van zoekopdrachten bewaakt. Django is hierbij niet louter een presentatiecomponent, maar beheert actief de levenscyclus van zoekopdrachten. Django beslist op basis van bestaande data of een scraping-opdracht noodzakelijk is en fungeert daarbij als Kafka-producer. Indien data ontbreekt of verouderd is, publiceert Django een bericht naar het Kafka-topic `scrape_jobs`. De verdere verwerking verloopt volledig asynchroon en zonder blokkering van de webserver.

4.3.2. Data-architectuur en modellering

Om frequente prijsupdates te ondersteunen en tegelijkertijd een duidelijke relatie tussen producten en winkels te behouden, werd de databank opgebouwd rond een genormaliseerd datamodel:

- `Shop`: representeert een retailer (bv. Albert Heijn, Carrefour, Colruyt).
- `Product`: stelt een generiek product voor, los van een specifieke winkel (bv. "volle melk").
- `ShopProduct`: vormt de verbindende entiteit tussen een `Shop` en een `Product`. Hier worden de effectieve prijsgegevens opgeslagen, waaronder `price_amount`, `price_per_unit`, `source_url` en `scraped_at`.

Om dataconsistentie te garanderen werd een uniciteitsconstraint toegepast op de combinatie van product en winkel, zodat per winkel maximaal één actuele prijs per product wordt bijgehouden.
Daarnaast werden de modellen `SearchQueryRun` en `SearchResult` geïntroduceerd om zoekopdrachten en bijhorende resultaten historisch bij te houden. Deze modellen maken het mogelijk om herhaalde zoekopdrachten binnen een bepaalde tijdspanne te herkennen en onnodige scraping te vermijden.

4.3.3. Zoekworkflow en asynchrone verwerking

Wanneer een gebruiker een zoekopdracht uitvoert via de interface, wordt een vaste beslissingslogica toegepast:

1. Eerst wordt de databank geraadpleegd om bestaande resultaten te vinden die overeenkomen met de zoekterm.
2. Indien resultaten beschikbaar zijn, wordt gecontroleerd of de bijhorende `scraped_at`-timestamp recenter is dan een vooraf gedefinieerde drempel (24 uur).
3. Indien geen resultaten beschikbaar zijn, of indien de data als verouderd wordt beschouwd, publiceert Django automatisch een scraping-opdracht naar Kafka.

Deze aanpak zorgt ervoor dat gebruikers altijd snel een antwoord krijgen, terwijl het systeem op de achtergrond zorgt voor het verversen van data. De webserver blokkeert hierbij niet op trage scraping-taken, maar blijft responsief.

4.3.4. Integratie met Kafka

De koppeling tussen de synchrone webinterface en de asynchrone scraping-infrastructuur wordt gerealiseerd via Kafka. Django fungeert hierbij als producer en publiceert berichten naar het `scrape_jobs`-topic. Deze berichten bevatten onder andere de zoekterm en de reden van de scraping-aanvraag.

Achtergrondprocessen, zoals de scraper worker en de normalizer service, consumeren deze berichten en voeren respectievelijk scraping en datanormalisatie uit. Zodra nieuwe data beschikbaar is, wordt de databank geüpdatet zonder tussenkomst van de gebruiker.
Deze ontkoppeling verhoogt de schaalbaarheid en betrouwbaarheid van het systeem, aangezien langdurige scraping-taken de gebruikersinterface niet beïnvloeden.

4.3.5. Gebruikersfunctionaliteiten

De gebruikersinterface biedt meerdere kernfunctionaliteiten:

Productzoekfunctie
Via een zoekpagina kan de gebruiker individuele producten opzoeken. De resultaten tonen prijzen van verschillende winkels, gesorteerd op de laagste prijs per eenheid. Indien data nog niet beschikbaar of verouderd is, wordt automatisch een achtergrondtaak gestart.

Slim winkelmandje
De interface ondersteunt ook het invoeren van meerdere producten tegelijk, gescheiden door komma's of nieuwe regels. Voor elk product wordt de goedkoopste winkel bepaald. Ontbrekende producten worden automatisch ingepland voor scraping, zonder dat de gebruiker expliciet actie moet ondernemen.

REST API
Naast HTML-pagina's voorziet de applicatie een REST API waarmee de frontend (of externe clients) de status van een zoekopdracht kunnen opvragen. Dit maakt het mogelijk om de interface dynamisch te updaten zonder volledige paginaherlading.

4.3.6. Statusmodellering en gebruikersfeedback

Wanneer een gebruiker een zoekopdracht uitvoert, wordt eerst de databank geraadpleegd op bestaande resultaten. Indien deze resultaten ontbreken of als verouderd worden beschouwd (ouder dan 24 uur), publiceert Django automatisch een scraping-opdracht naar Kafka.
Om transparantie te bieden aan de gebruiker maakt de interface gebruik van expliciete statussen:

Status	Betekenis	Systeemactie
`gereed`	Data is actueel	Resultaten worden direct weergegeven
`in wachtrij`	Data ontbreekt of is verouderd	Scraping-opdracht wordt gestart

Hierdoor ervaart de gebruiker steeds een snelle respons met al opgeslagen data, ongeacht de duur van de achterliggende scraping.

4.3.7. Conclusie

De Django-gebaseerde gebruikersinterface functioneert als een toestand gedreven coördinatielaag die de volledige levenscyclus van een zoekopdracht beheert. Door het combineren van caching, asynchrone verwerking en duidelijke gebruikersfeedback slaagt het systeem erin om zowel actuele prijsinformatie als een snelle en responsieve gebruikerservaring te bieden.

4.4. Scrapinglaag

4.4.1. Scrapy

Scrapy is een snel en krachtig Python-framework voor webscraping Scrapy Developers, z.d. Het stelt je in staat om crawlers (spiders) te bouwen die efficiënt gestructureerde data (zoals productinformatie en prijzen) van websites extraheren door pagina's op te halen, HTML/XML te parsen (met behulp van selectors zoals XPath/CSS) en de resultaten te exporteren (CSV, JSON). Het framework verwerkt grootschalige crawling asynchroon, waardoor het uitstekend geschikt is voor data mining, monitoring en automatisering.

4.4.2. Algemene ontwikkelingsmethodologie van de spiders

De ontwikkeling van elke scraper binnen dit project volgde een systematische en herhaalbare analysemethode, ongeacht de specifieke technologie van de doelwebsite. Deze methode bestaat uit het analyseren van HTML-structuren, het inspecteren van netwerkverkeer en het identificeren van geschikte data-ingangspunten. Door deze gestructureerde aanpak kon per supermarkt de meest geschikte scrapingtechniek worden gekozen.

Analyse van HTML-structuren

De eerste stap in de ontwikkeling van elke spider bestond uit het analyseren van de HTML-structuur van de zoekresultaatpagina's. Met behulp van browserontwikkeltools werden DOM-elementen geïnspecteerd om te bepalen waar productinformatie zich bevindt en of deze server-side dan wel client-side wordt gerenderd. Hierbij werd specifiek gekeken naar herhaalbare HTML-blokken (zoals productkaarten), consistente CSS-klassen en data-attributen die gebruikt worden voor identificatie en tracking.

Volgens (Mitchell, 2018) vormt DOM-analyse de fundamentele basis van HTML-gebaseerde web scraping, omdat stabiele en semantisch betekenisvolle structuren doorgaans minder frequent wijzigen dan visuele layout-elementen . Deze observatie werd bevestigd bij de implementatie van de Carrefour spider, waar server-side gerenderde

HTML voldoende stabiel bleek voor klassieke parsing met CSS-selectors.

Inspectie van netwerkverkeer
Wanneer HTML-analyse wees op beperkte of ontbrekende data in de initiële DOM, werd de aandacht verlegd naar netwerkverkeer. Via het Network-tabblad van browserontwikkeltools werden HTTP-requests geanalyseerd die uitgevoerd worden bij het laden van zoekresultaten of bij interacties zoals paginatie en scrollen.
Deze stap maakte het mogelijk om verborgen API-aanroepen te identificeren, zoals JSON- of GraphQL-endpoints die productdata rechtstreeks leveren. Dit bleek cruciaal bij de ontwikkeling van de Albert Heijn spider, waar productinformatie niet primair in HTML aanwezig was, maar via een GraphQL-endpoint werd aangeleverd. Het benutten van dergelijke endpoints sluit aan bij aanbevelingen uit de literatuur, waar wordt gesteld dat directe communicatie met backend-API's robuuster en efficiënter is dan HTML-parsing indien beschikbaar (Almeida & Silva, 2020).

Analyse van request- en responsepatronen
Naast het identificeren van endpoints werd ook aandacht besteed aan request headers, HTTP-methodes en payloadstructuren. Door deze parameters correct te repliceren (zoals `Content-Type`, `Origin` en `Referer`) konden requests succesvol nagebootst worden als regulier browserverkeer. Dit verkleint de kans op detectie door eenvoudige anti-botmechanismen en verhoogt de betrouwbaarheid van de scraper (Zhao & Zhang, 2021).

Detectie van client-side rendering
Wanneer noch HTML-parsing noch directe API-aanroepen voldoende data opleverden, werd vastgesteld dat de website afhankelijk is van client-side JavaScript-rendering. In dergelijke gevallen werd een headless browser ingezet om de pagina volledig te renderen alvorens data-extractie plaatsvond. Dit scenario deed zich voor bij Colruyt, waar productkaarten pas na uitvoering van JavaScript en interne API-calls beschikbaar waren.
Onderzoek toont aan dat moderne e-commerceplatformen steeds vaker client-side rendering combineren met anti-botmaatregelen, waardoor headless browsers zoals Playwright of Puppeteer noodzakelijk worden voor betrouwbare scraping (Li & Kumar, 2022).

Iteratieve validatie en verfijning
De analysefase werd iteratief herhaald tijdens de ontwikkeling. Wijzigingen in frontendgedrag, time-outs of blokkades leidden tot hernieuwde inspectie van netwerkverkeer en DOM-structuren. Deze feedbackloop maakte het mogelijk om scrapinglogica incrementeel te verbeteren en aan te passen aan veranderende omstandigheden, wat essentieel is voor scraping in productieomgevingen (Olston & Najork,

2010).

4.4.3. Initiële aanpak en beperkingen

In een eerste experimentele fase werd gebruikgemaakt van de combinatie *Requests* en *BeautifulSoup*. Hoewel deze aanpak eenvoudig te implementeren is, bleek ze in de praktijk onvoldoende robuust. Tijdens tests werden meerdere HTTP-foutcodes waargenomen, waaronder 403 (Forbidden), 456 (Quota exceeded). Bovendien werd vastgesteld dat bepaalde websites, zoals Carrefour, gebruikmaken van Cloudflare om niet-menselijk verkeer te detecteren en te blokkeren met boodschappen zoals te zien in Figuur 4.3.

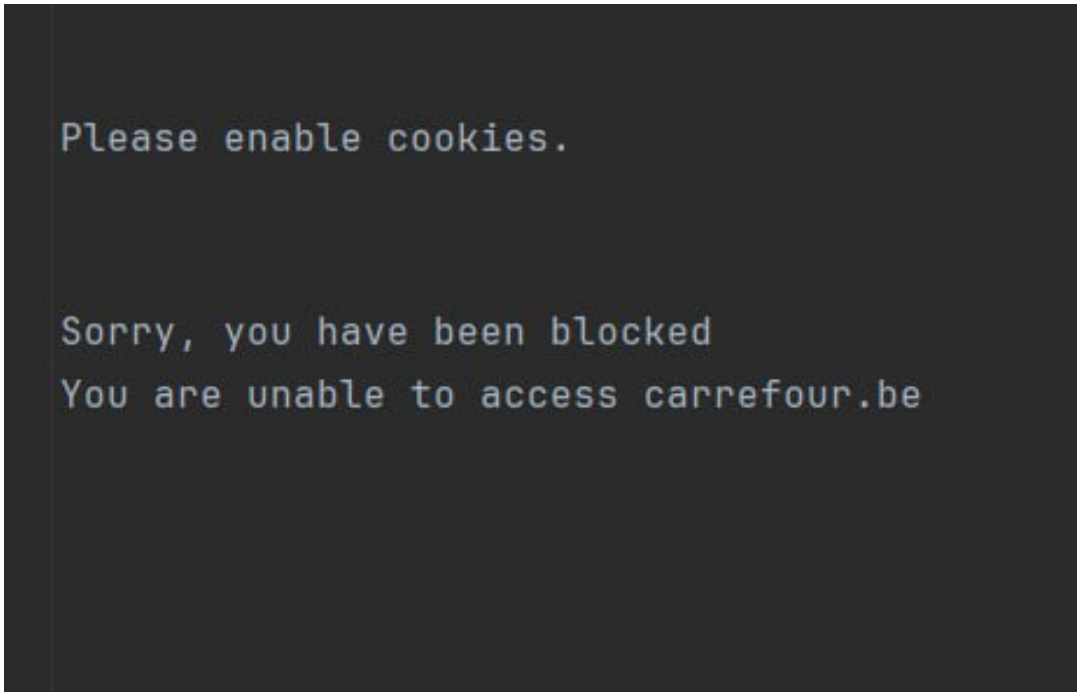

Figuur 4.3: Gedetecteerd met BeautifulSoup

4.4.4. Overstap naar Scrapy en Playwright

Op advies van de co-promotor werd overgestapt naar het Scrapy-framework. Scrapy biedt uitgebreide mogelijkheden voor request scheduling, foutafhandeling en data-extractie, en is gebaseerd op een asynchrone, event-gedreven architectuur. Door het scrapingproces te mogen isoleren en als een afzonderlijke service of proces uit te voeren, wordt het systeem beter bestand tegen fouten en netwerkproblemen. Hierdoor blijft de rest van de applicatie operationeel, zelfs wanneer scraping taken falen of tijdelijk onderbroken worden. Daarnaast om detectie te vermijden, wordt gebruikgemaakt van *scrapy-impersonate*, waarmee browserheaders en gebruikersgedrag geïmiteerd kunnen worden. Voor websites met dynamische content werd Scrapy gecombineerd met Playwright, zodat JavaScript-elementen correct kunnen worden geladen.

4.4.5. Website-specifieke scrapingstrategieën

Voor de verschillende webshops werden specifieke scrapingstrategieën toegepast:

- **Albert Heijn**: data wordt opgehaald via de GraphQL-API, waarbij JSON-responses worden gekregen.
- **Carrefour**: HTML-scraping met Scrapy en browser-imitatie.
- **Colruyt**: scraping met Scrapy in combinatie met Playwright om JavaScript-gegenereerde content te laden.

4.4.6. Orkestratie van scraping taken

`scraper_worker.py` — Orchestrator

Het script `scraper_worker.py` fungeert als centrale orkestrator van scraping-opdrachten. Dit proces luistert continu naar het Kafka-topic `scrape_jobs` en verwerkt telkens één job tegelijk.
Bij ontvangst van een job:

1. wordt de zoekterm gevalideerd;
2. wordt gecontroleerd of de job recent reeds werd uitgevoerd;
3. wordt de scraping-opdracht gestart via `run_all(query)`.

Door deze centrale coördinatie wordt vermeden dat meerdere workers dezelfde scraping-taak gelijktijdig uitvoeren.

Listing 4.1: Kafka consumer loop in `scraper_worker.py` (vereenvoudigd)

```
consumer = KafkaConsumer(
    TOPIC,
    bootstrap_servers=BOOTSTRAP,
    group_id=GROUP_ID,
    enable_auto_commit=False,
    auto_offset_reset="earliest",
    value_deserializer=lambda b: json.loads(b.decode("utf-8")),
    consumer_timeout_ms=1000,
    max_poll_records=1,
)

for msg in consumer:
    job = msg.value or {}
    query = (job.get("query") or "").strip()
    if not query:
        consumer.commit()
        continue

    try:
```

```
        run_all(query)      # start spiders
        consumer.commit()   # ack job
    except Exception:
        # don't commit -> retry
        time.sleep(5)
```

run_spiders.py — Procesisolatie

Scrapy maakt gebruik van de Twisted reactor, die niet opnieuw kan worden gestart binnen hetzelfde proces. Om dit probleem te vermijden lanceert `run_spiders.py` alle spiders in een afzonderlijk multiprocessing-proces.
Deze aanpak:

Listing 4.2: Procesisolatie voor Scrapy/Twisted in `run_spiders.py` (vereenvoudigd)

```
def _run_crawler_process(query: str):
    settings = get_project_settings()
    process = CrawlerProcess(settings)
    process.crawl(AHSpider, query=query)
    process.crawl(CarrefourSpider, query=query)
    process.crawl(ColruytSpider, query=query)
    process.start()

def run_all(query: str):
    p = multiprocessing.Process(target=_run_crawler_process, args=(query,)
   )
    p.start()
    p.join()
```

Het voorkomt reactor-gerelateerde crashes, verhoogt de stabiliteit van de worker, laat toe om falende spiders te isoleren.

4.4.7. Albert Heijn (AH)

Implementatie van een GraphQL-gebaseerde scraper

In tegenstelling tot webshops die voornamelijk HTML-rendering gebruiken, biedt Albert Heijn productzoekresultaten aan via een GraphQL-laag. Om deze data op een stabiele en performante manier te verzamelen, werd een Scrapy spider geïmplementeerd die rechtstreeks communiceert met het GraphQL-endpoint van AH via HTTP POST requests. De inspiratie voor deze aanpak werd gevonden in een bestaande repository (Westera, z.d.).

GraphQL-query als contract voor data-extractie

De spider maakt gebruik van een vaste GraphQL-query (`PRODUCT_SEARCH`) die in een hulpfunctiebestand werd ondergebracht.

Listing 4.3: GraphQL zoekquery voor Albert Heijn (`PRODUCT_SEARCH`)

```
PRODUCT_SEARCH = """
```

```
query {
  productSearch(input: {query: "%s"}) {
    page { pageSize pageNumber totalPages totalElements }
    products {
      id
      brand
      title
      summary
      price {
        now { amount formatted }
        unitInfo {
          price { amount formatted }
          description
        }
      }
    }
  }
}
"""
```

Deze query definieert expliciet welke velden nodig zijn voor het prijsvergelijkingsplatform, waaronder paginatie-informatie en essentiële productvelden zoals titel, merk, prijs en eenheidsprijs. De query werd als string-template geïmplementeerd, waarbij de gebruikerszoekterm dynamisch ingevuld wordt (`"%s"`). Dit maakt het mogelijk om met dezelfde query-structuur verschillende zoekopdrachten uit te voeren. (Zie `scripts/util.py`.)

Request-opbouw en communicatie met het endpoint

De effectieve scraping gebeurt door het versturen van een POST request naar het GraphQL-endpoint van AH, met als body een JSON payload waarin de query-string wordt meegegeven. De spider voorziet daarnaast specifieke HTTP headers zoals `Content-Type`, `Accept`, `Origin` en `Referer`. Dit zorgt ervoor dat het request voldoende lijkt op normaal browsergedrag en verhoogt de slaagkans in een productieomgeving. (Zie `scripts/ah_spider.py`.)

Parsing en normalisatie van het GraphQL-responseformaat

De response van het endpoint bevat JSON-data met een vaste structuur: `data.productSearch.pag` bevat paginatievelden en `data.productSearch.products` bevat de productlijst. Per product worden prijsvelden uitgenest uit `price.now` (actuele prijs) en `price.unitInfo.price` (eenheidsprijs). De spider yieldt vervolgens per product een gestandaardiseerd record met onder meer:

- `id`, `brand`, `title`, `summary`
- `price_amount` (huidige prijs)

- `price_per_unit` (eenheidsprijs)
- `unit` (beschrijving van de eenheid)
- `price_scraped_at` (timestamp)

Deze velden vormen de basis voor verdere normalisatie en opslag downstream in de pipeline. (Zie `scripts/ah_spider.py`.)

Waarom GraphQL (en hoe het schema werd bepaald)
Een praktisch voordeel van GraphQL is dat de client precies kan opvragen welke velden nodig zijn, zonder bijkomende HTML-parsing of meerdere REST-calls. Om de beschikbare queries en datavelden van AH te achterhalen, werd gebruikgemaakt van schema-visualisatie via GraphQL Voyager gevonden in de repository (Westera, z.d.) Daarnaast werd het reverse-engineering proces ondersteund door bestaande documentatie en voorbeeldimplementaties uit een open-source repository die het AH GraphQL-schema via introspection beschrijft en illustreert.

Robuustheid en anti-bot overwegingen
Hoewel deze spider geen headless browser nodig heeft, werd wel rekening gehouden met anti-botmaatregelen. Daarom gebruikt de spider Scrapy-instellingen die typische browser fingerprinting beperken, zoals het gebruik van `scrapy_impersonate` middleware en het uitschakelen van een vaste `USER_AGENT`. Dit verhoogt de betrouwbaarheid van requests naar het endpoint. (Zie `scripts/ah_spider.py`.)

Conclusie
Door rechtstreeks met het GraphQL-endpoint te communiceren, vermijdt de AH scraper de fragiliteit van HTML-scraping en kan productdata efficiënt en consistent verzameld worden. De combinatie van een vaste query-structuur (`PRODUCT_SEARCH`) en gecontroleerde request-headers levert een stabiele basis voor verdere verwerking in de event-driven scraping pipeline.

4.4.8. Carrefour

HTML-gebaseerde scraping met dynamische paginatie
In tegenstelling tot Albert Heijn, waar productgegevens via een GraphQL-endpoint beschikbaar zijn, presenteert Carrefour zijn zoekresultaten hoofdzakelijk als server-side gerenderde HTML-pagina's. Om deze data betrouwbaar te extraheren werd een Scrapy spider ontwikkeld die gebruikmaakt van klassieke HTML-parsing via CSS-selectors, aangevuld met browser-impersonatie om anti-botmaatregelen te omzeilen.
De implementatie van deze spider bevindt zich in `carrefour_spider.py`.

Zoekgebaseerde URL-opbouw en paginatie
De scraper werkt op basis van een zoekterm die dynamisch wordt meegegeven bij het initialiseren van de spider. De zoekterm wordt geïnjecteerd in de basis-URL van Carrefour, waarna paginatie gebeurt door incrementeel een paginaparameter (`p`) toe te voegen aan de querystring.
De spider start op pagina 1 en blijft nieuwe pagina's opvragen zolang er producten worden aangetroffen. Dit mechanisme maakt het mogelijk om volledige zoekresultaten te scrapen zonder vooraf kennis te hebben van het totaal aantal pagina's.

Detectie van einde van zoekresultaten
Om te vermijden dat onnodige requests worden uitgevoerd, controleert de spider of alle producten reeds zijn weergegeven. Dit gebeurt via een HTML-element dat door Carrefour gebruikt wordt als voortgangsindicator (`div.progress`). De attributen `data-shown-items` en `data-total-items` worden met elkaar vergeleken om te bepalen of verdere paginatie nodig is.
Wanneer het aantal getoonde items gelijk is aan het totaal aantal beschikbare items, stopt de spider automatisch met verdere requests. Deze logica voorkomt overbodige netwerkbelasting en verhoogt de efficiëntie van het scrapingproces.

Browser-impersonatie en anti-bot mitigatie
Carrefour implementeert basisvormen van botdetectie op basis van HTTP headers en browserkenmerken. Om dit te omzeilen maakt de spider gebruik van de `scrapy_impersonate` download handler en middleware.
Concreet:

- worden requests uitgevoerd met een willekeurige, realistische browserfingerprint;
- wordt geen vaste `USER_AGENT` gebruikt;
- wordt het Twisted `AsyncioSelectorReactor` expliciet geconfigureerd om compatibiliteit met moderne asynchrone netwerkstacken te garanderen.

Deze aanpak verhoogt de betrouwbaarheid van de scraper aanzienlijk zonder de overhead van een volledige headless browser, zoals bij Playwright.

Extractie en normalisatie van productgegevens
Per productkaart worden relevante velden geëxtraheerd via CSS-selectors, waaronder:

- merk en producttitel;
- actuele prijs;
- eenheidsprijs (prijs per kg/l);

- eenheidsbeschrijving;
- bron-URL en timestamp.

De eenheidsprijs wordt bijkomend genormaliseerd via een hulpfunctie (`price_per_kg_extractor`), die numerieke waarden extraheert uit tekstuele prijsstrings. Numerieke conversies worden afgehandeld via een robuuste `parse_decimal`-functie om fouten door locale-specifieke notaties (komma versus punt) te vermijden. (Zie `util.py`.)

Fouttolerantie en logging
Na het parsen van elke pagina wordt gelogd hoeveel producten succesvol werden geëxtraheerd. Indien een pagina geen producten bevat, stopt de paginatie automatisch. Deze eenvoudige maar effectieve controle voorkomt oneindige loops en vergemakkelijkt debugging tijdens runtime.

Conclusie
De Carrefour scraper illustreert een klassieke maar efficiënte HTML-gebaseerde scraping-aanpak, waarbij performantie en stabiliteit centraal staan. Door het combineren van server-side HTML parsing, browser-impersonatie en slimme paginatiecontrole kan productdata betrouwbaar verzameld worden zonder de complexiteit van een headless browser.
In combinatie met de GraphQL-gebaseerde AH scraper en de Playwright-gedreven Colruyt scraper toont deze implementatie aan dat de scraping-architectuur flexibel genoeg is om verschillende technische ecosystemen binnen één uniform verwerkingsmodel te ondersteunen.

4.4.9. Colruyt

Ontwikkeling en optimalisatie van een robuuste Colruyt webscraper
Tijdens de ontwikkeling van het prijsvergelijkingsplatform bleek het scrapen van productgegevens van de Colruyt-website uitzonderlijk complex. In tegenstelling tot andere supermarkten maakt Colruyt intensief gebruik van client-side rendering, trage backend-API's en geavanceerde anti-botmaatregelen. Deze combinatie leidde in de initiële implementatie tot frequente `TimeoutError`-exceptions, blokkades en onbetrouwbare dataverzameling.
Om deze problemen structureel op te lossen werd de oorspronkelijke Scrapy-Playwright spider iteratief herwerkt tot een robuuste en fouttolerante scraping-oplossing. De uiteindelijke optimalisaties focussen op navigatiestrategie, browser stealth, resourcebeheer en state handling.

Initiële implementatie
De oorspronkelijke Colruyt-scraper werd geïmplementeerd als een standaard Scrapy spider met ondersteuning van `scrapy-playwright`. De configuratie maakte gebruik van de standaard Playwright-navigatiestrategie waarbij gewacht wordt tot

het `load`-event wordt getriggerd, wat impliceert dat alle pagina-assets volledig geladen zijn.
Daarnaast:

- werd de standaard navigatie-time-out van 60 seconden gebruikt;
- waren stealthmaatregelen beperkt tot het overschrijven van `navigator.webdriver`;
- werden alle resources (afbeeldingen, fonts, trackers en scripts) zonder filtering geladen;
- werd elke paginatie-aanvraag behandeld als een nieuwe browsercontext zonder expliciete state-afhandeling.

Hoewel deze aanpak functioneel correct was, bleek ze ongeschikt voor stabiele scraping in een productieomgeving.

Geïdentificeerde problemen

Tijdens testen en deployment werden meerdere structurele problemen vastgesteld:

Timeout

Tijdens scraping van Colruyt trad sporadisch een `playwright._impl._errors.TimeoutError` op, zowel bij de initiële scrape als bij paginatie (bv. pagina 2 voor zoekterm “ijs”). Dit werd veroorzaakt doordat de Colruyt-website achtergrondprocessen en tracking-API’s laadt die traag reageren of soms nooit afronden, waardoor het `load`-event niet wordt bereikt. Daarnaast de fout ontstond in de Playwright-integratie wanneer expliciet werd gewacht tot de productkaarten *zichtbaar* waren: `Page.wait_for_selector("a.card-article[data-tms-product-id]")` met een time-out van 45 seconden. Dit is visueel waarneembaar in Figuur 4.4. In dergelijke gevallen is de pagina wel geladen, maar blijven productkaarten onzichtbaar door trage JavaScript-rendering, overlays (cookie banner) of anti-bot interventies, waardoor de zichtbaarheid-conditie niet wordt voldaan.
Om dit robuuster te maken werd de readiness-conditie aangepast: in plaats van te wachten op `visible` werd gewacht op `attached` (aanwezig in de DOM). Dit reduceert false negatives op dynamische pagina’s en laat toe om nadien expliciet scroll- en wachttactieken toe te passen indien lazy-loading vereist is (zie implementatie in de Colruyt spider).

Anti-bot detectie

De website detecteerde de browser als geautomatiseerd verkeer, wat resulteerde in HTTP 456-responses of redirects naar blokkadepagina’s. De beperkte stealthmaatregelen waren onvoldoende tegen moderne browser fingerprinting.

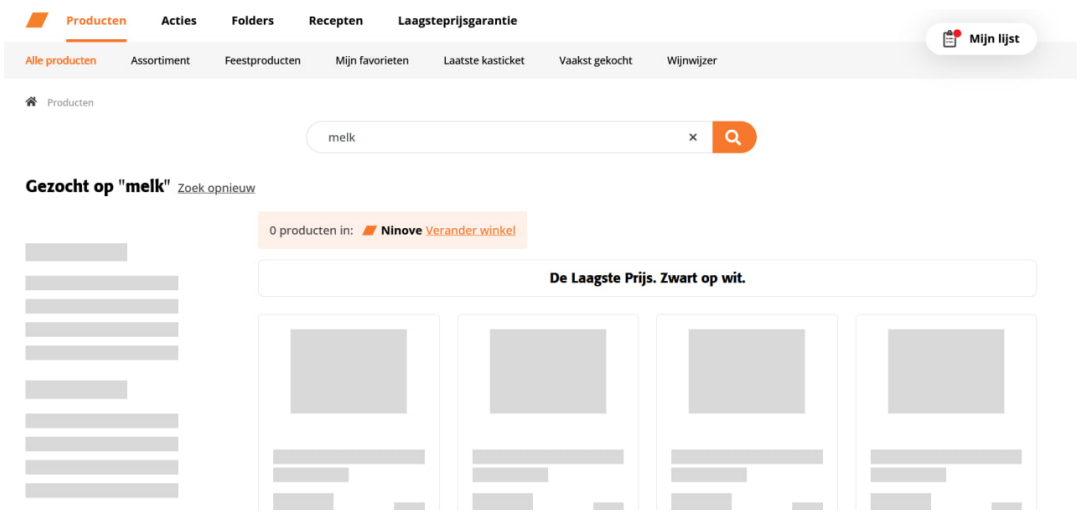

Figuur 4.4: Schermafbeelding browser

Cookie banner-interferentie

Bij elke nieuwe pagina verscheen een cookie consent overlay 4.5. Omdat Scrapy-Playwright vaak nieuwe browsercontexten gebruikt, bedekte deze banner de productkaarten bij paginatie, waardoor `wait_for_selector`-logica faalde.

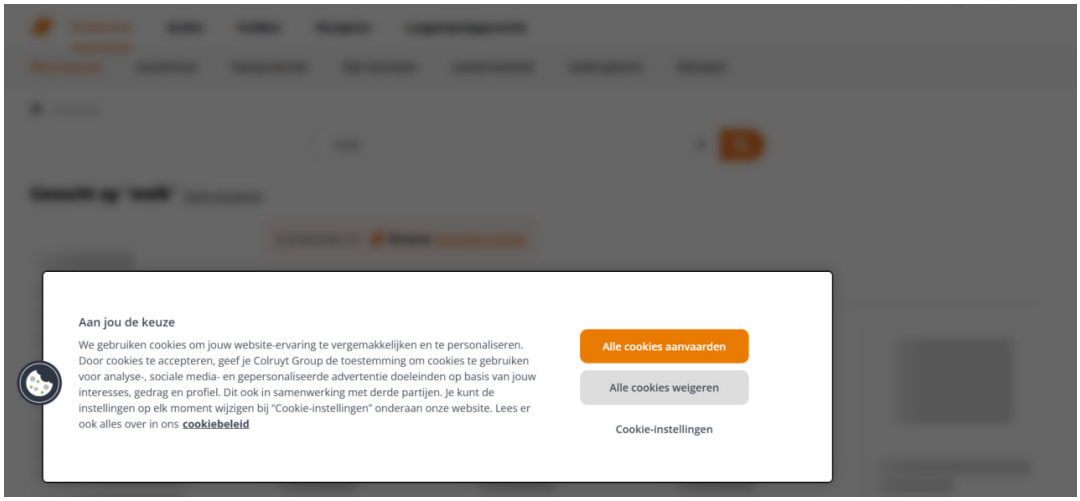

Figuur 4.5: Schermafbeelding browser

Onvolledige rendering

In sommige gevallen rapporteerde Playwright dat de pagina geladen was, terwijl productkaarten slechts als skeleton placeholders aanwezig waren omdat interne JavaScript-logica nog niet voltooid was.

Volgende pagina scraping

Om alle gevonden producten te kunnen scrapen moeten er alle paginas geladen en gescraped worden. Om dit te ondersteunen werden twee benaderingen ge-

combineerd: 1. Er wordt de aantal van gevonden producten gelezen uit HTML blok `promo-filters__overview` die op 4.6 wordt getoond. 2. Er wordt gekeken of er een knop ”Meer bekijken” staat die te zien is op 4.7. Als die niet gevonden is, dan betekent het voor Colruyt spider en voor een gebruiker dat het de laatste pagina met de producten gefilterdert met gevraagde product naam.

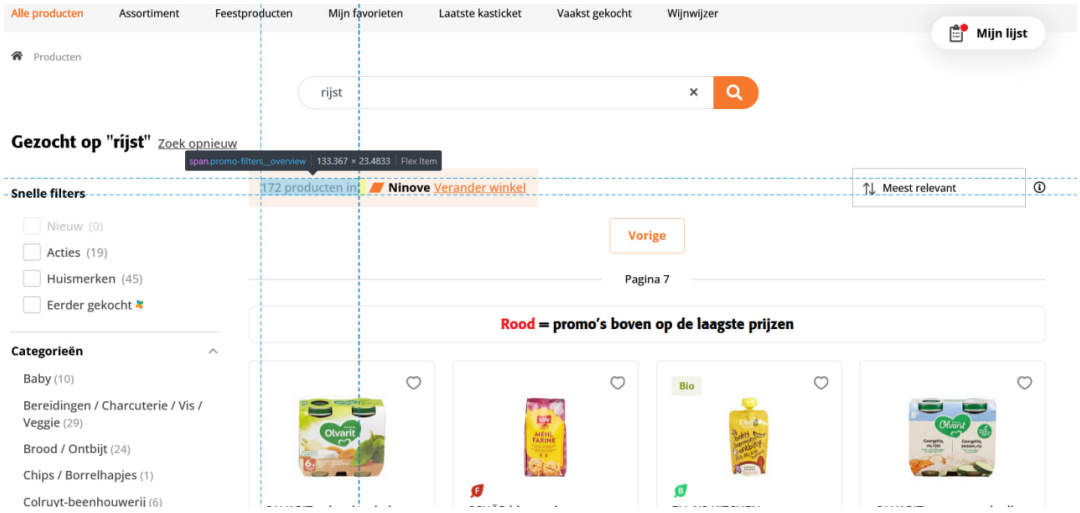

Figuur 4.6: Schermafbeelding browser van Colruyt met HTML element

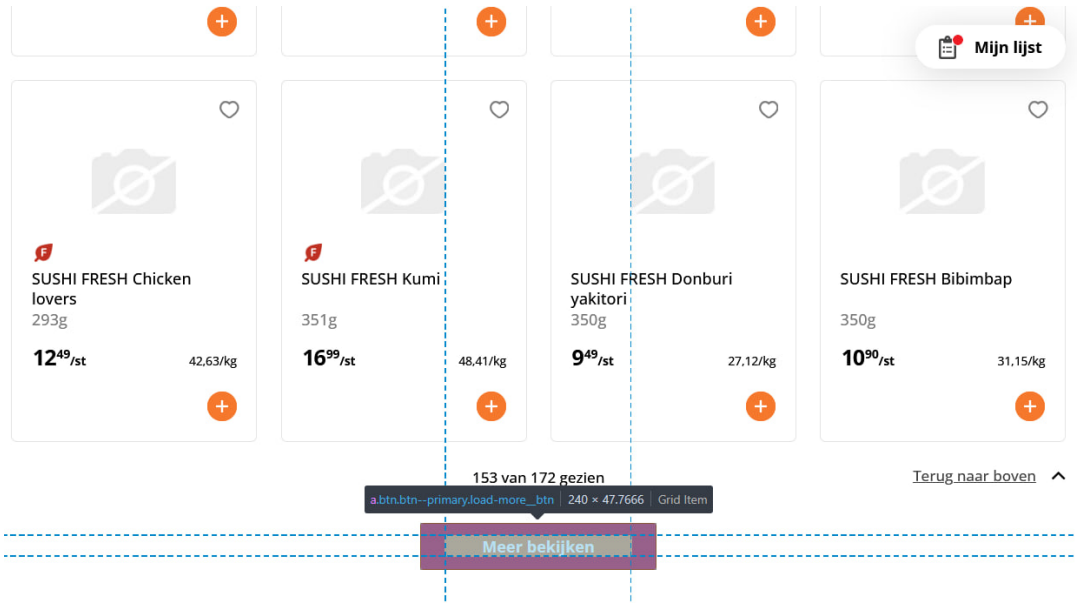

Figuur 4.7: Schermafbeelding browser van Colruyt met HTML element: button.

Geïmplementeerde optimalisaties

1. Geoptimaliseerde navigatiestrategie

De navigatiestrategie werd aangepast door expliciet te wachten op `domcontent-loaded` in plaats van het `load`-event. Dit werd gerealiseerd via een aangepaste Playwright-configuratie in de spider (`custom_settings`):

Listing 4.4: Playwright PageMethods in de Colruyt spider (uittreksel)

```
yield scrapy.Request(
    url,
    headers=self.HEADERS,
    callback=self.parse,
    meta={
        "playwright": True,
        "playwright_include_page": True,
        "playwright_page_methods": [
            PageMethod("wait_for_load_state", "domcontentloaded"),
            PageMethod("wait_for_selector", "a.card--article[data-tms-
   product-id]"),
            PageMethod("add_init_script",
                       "Object.defineProperty(navigator, 'webdriver', {get:
    () => undefined})"),
        ],
    },
)
```

- `PLAYWRIGHT_DEFAULT_NAVIGATION_TIMEOUT` werd verhoogd tot 90 seconden;
- `wait_for_selector` werd gebruikt met een verhoogde time-out van 45 seconden om te wachten op volledig gerenderde productkaarten (`a.card–article[data-tms-product-id]`).

Deze aanpak laat toe om de HTML-structuur vroegtijdig te verwerken zonder te blokkeren op niet-essentiële assets.

2. Geavanceerde browser stealth

Om anti-bot detectie te minimaliseren werd een multi-layered stealth-aanpak geïmplementeerd via `PageMethod(ädd_init_script", ...)`. Hierbij werden onder andere de volgende eigenschappen overschreven vóór uitvoering van paginascripts:

- `navigator.webdriver`
- `navigator.languages`
- `navigator.plugins`

Daarnaast werden Chromium launch-argumenten toegevoegd zoals `–disable-blink-features=AutomationControlled`. Hierdoor gedraagt de browser zich vrijwel identiek aan een reguliere Chrome-browser, wat fingerprinting aanzienlijk bemoeilijkt.

3. Selectieve resource filtering
Om laadtijden te reduceren en time-outs te vermijden werd resource filtering toegepast. Niet-essentiële assets zoals afbeeldingen, fonts en externe tracking scripts (bijv. Google Analytics en Facebook trackers) werden geblokkeerd.
CSS-bestanden werden expliciet toegestaan, aangezien bepaalde JavaScript-componenten afhankelijk zijn van layout- en zichtbaarheidberekeningen voor correcte rendering van productkaarten. Deze keuze bleek cruciaal voor betrouwbare dataverzameling.

4. Automatische UI-state afhandeling
Omdat cookie banners bij elke nieuwe browsercontext opnieuw verschenen, werd een herhaald script geïnjecteerd dat automatisch de "Accept All Cookies"-knop detecteert en aanklikt. Deze logica werd geïntegreerd via `add_init_script` en wordt periodiek uitgevoerd zolang de pagina actief is.
Dit garandeert dat productkaarten steeds zichtbaar blijven, zowel bij initiële pagina's als bij paginatie.

5. Stabiliteit en resourcebeheer
Om geheugenlekken en ophoping van browserprocessen te vermijden werd de parsing-logica omhuld met een `try ... finally`-constructie waarin de Playwright `page` expliciet wordt afgesloten. Dit is essentieel voor langdurige uitvoering binnen een containerized omgeving.
Daarnaast werden expliciete controles toegevoegd voor HTTP 456-responses en geblokkeerde URL's, zodat failures correct gelogd worden in plaats van te resulteren in stille time-outs.

Resultaat
Door deze iteratieve optimalisaties werd de Colruyt-scraper getransformeerd van een fragiele proof-of-concept naar een stabiele en productieklare scrapingcomponent. De scraper is nu in staat om:

- complexe JavaScript-gedreven pagina's betrouwbaar te verwerken;
- anti-botmaatregelen grotendeels te omzeilen;
- consistente productdata te extraheren;
- langdurig te draaien zonder resource-uitputting.

Deze aanpak minimaliseert blokkades en verhoogt de betrouwbaarheid van het scrapingproces aanzienlijk. Eindarchitectuur is te zien in figuur 4.8.

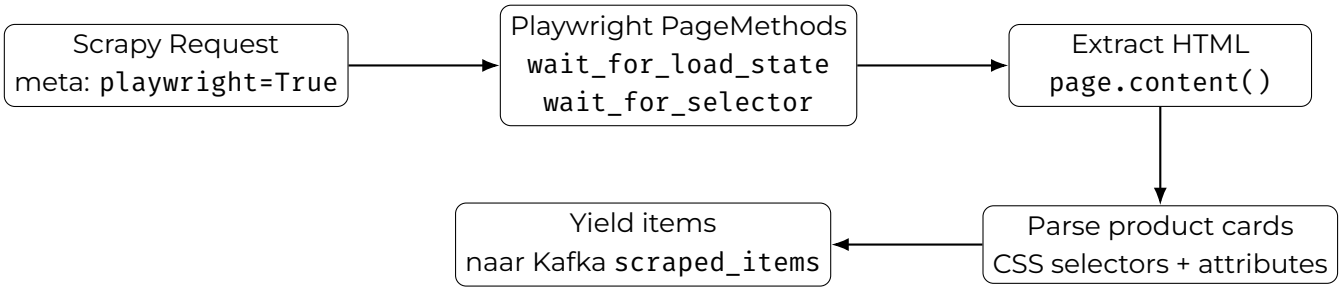

Figuur 4.8: Colruyt scraping flow met Scrapy-Playwright: requests renderen in een headless browser waarna HTML wordt uitgelezen en geparsed.

4.4.10. Vergelijking van scraping-strategieën

Kenmerk	Albert Heijn	Carrefour	Colruyt
Databron	GraphQL API	Server-side HTML	Client-side JavaScript
Scraping-techniek	HTTP POST (JSON)	Scrapy HTML parsing	Scrapy + Playwright
Rendering nodig	Nee	Nee	Ja (headless browser)
Anti-bot complexiteit	Laag	Gemiddeld	Hoog
Stealthmaatregelen	Headers + impersonatie	Browser impersonatie	Multi-layer stealth + fingerprint spoofing
Paginatie	GraphQL response metadata	URL-parameter (p)	Query-parameter + JS-rendering
Performantie	Zeer hoog	Hoog	Lager
Foutgevoeligheid	Laag	Gemiddeld	Hoog (zonder mitigaties)
Onderhoudbaarheid	Zeer goed	Goed	Complex
Gebruik Playwright	Nee	Nee	Ja

Tabel 4.1: Vergelijking van scraping-strategieën per supermarkt

Analyse en motivatie van de gekozen aanpak

Tabel 4.1 toont duidelijk aan dat voor elke supermarkt een verschillende scraping-strategie werd toegepast, afgestemd op de onderliggende technische architectuur van de website. Deze bron-specifieke benadering was noodzakelijk om zowel performantie als betrouwbaarheid te maximaliseren.

Albert Heijn

Albert Heijn biedt productdata aan via een GraphQL-endpoint, wat directe en gestructureerde toegang tot prijs- en productinformatie mogelijk maakt. Hierdoor is geen HTML-parsing of JavaScript-rendering vereist. De scraper communiceert rechtstreeks met het backend-systeem via HTTP POST requests en ontvangt JSON-responses met een voorspelbare structuur. Deze aanpak resulteert in een zeer hoge performantie en lage foutgevoeligheid, aangezien wijzigingen in de frontend geen impact hebben op de scraping-logica.

Carrefour

Carrefour presenteert zijn zoekresultaten hoofdzakelijk als server-side gerenderde HTML-pagina's. Hierdoor volstaat klassieke HTML-parsing met CSS-selectors. Omdat er geen complexe client-side rendering nodig is, kan scraping gebeuren zonder headless browser, wat de performantie ten goede komt. Wel zijn beperkte anti-botmaatregelen aanwezig, waardoor browser-impersonatie werd ingezet om requests te laten lijken op regulier gebruikersverkeer.

Colruyt

Colruyt vormt het meest complexe scraping-scenario. De website is sterk afhankelijk van client-side JavaScript, lazy-loading en interne API-calls, gecombineerd met actieve anti-botdetectie. Hierdoor is het gebruik van een headless browser (Playwright) noodzakelijk om de pagina correct te renderen voordat data geëxtraheerd kan worden. Deze aanpak is intrinsiek trager en foutgevoeliger, maar onvermijdelijk om betrouwbare data te verkrijgen. Om dit te mitigeren werden geavanceerde stealthmaatregelen, aangepaste navigatiestrategieën en expliciet resourcebeheer geïmplementeerd.

Overkoepelende conclusie

De vergelijking toont aan dat een uniforme scraping-oplossing onvoldoende zou zijn voor dit project. Door per databron de meest geschikte techniek te kiezen - GraphQL waar mogelijk, HTML-parsing waar voldoende, en headless rendering waar noodzakelijk - wordt een optimale balans bereikt tussen performantie, stabiliteit en onderhoudbaarheid. Deze gelaagde aanpak onderstreept de flexibiliteit en schaalbaarheid van de gekozen scraping-architectuur.

4.5. Opslag van ruwe data

De spiders sturen hun resultaten niet rechtstreeks naar de databank, maar publiceren ruwe JSON-berichten naar het Kafka-topic `scraped_items`. Kafka fungeert hierbij als buffer en ontkoppelingslaag tussen scraping en dataverwerking. Deze keuze biedt meerdere voordelen. Ten eerste kan data opnieuw verwerkt worden zonder opnieuw te scrapen. Ten tweede blijft de oorspronkelijke brondata beschikbaar voor validatie en foutanalyse. Verder maakt deze tussenlaag het systeem tolerant voor tijdelijke fouten en piekbelasting.
Deze stap sluit conceptueel aan bij event-gedreven architecturen waarbij data eerst als onbewerkte events wordt opgeslagen.

4.6. Transformatielaag

De normalizer consumeert berichten van het `scraped_items`-topic en is verantwoordelijk voor:

- productnamen opgeschoond;
- prijsnotaties genormaliseerd;
- eenheden geharmoniseerd;
- irrelevante HTML-elementen verwijderd.

Via `update_or_create` worden bestaande prijsrecords geüpdatet, wat voorkomt dat duplicaten ontstaan bij herhaalde scraping.

Listing 4.5: Normalisatie en persistente opslag in `normalizer.py` (vereenvoudigd)

```
def parse_decimal(value):
    try:
        return Decimal(str(value).replace(",", "."))
    except Exception:
        return None

shop, _ = Shop.objects.get_or_create(name=store_name)
product, _ = Product.objects.get_or_create(name=product_name)

ShopProduct.objects.update_or_create(
    product=product,
    shop=shop,
    defaults={
        "price_per_unit": price_per_unit,
        "barcode": barcode,
        "source_url": source_url,
        "scraped_at": scraped_at,
    },
)
```

Door transformatie los te koppelen van scraping wordt het systeem beter onderhoudbaar en uitbreidbaar.

4.7. Gestructureerde opslag

Na normalisatie wordt de data opgeslagen in een PostgreSQL-databank via Django ORM. De databank bevat onder meer: Shop, Product, ShopProduct. Deze structuur laat toe om prijzen per winkel te vergelijken en historische updates bij te houden.

4.8. Optimalisatie van productmatching

In de initiële implementatie van de zoek- en winkelmandfunctionaliteit werd productmatching uitgevoerd via een eenvoudige substring-vergelijking op databankniveau, gebruikmakend van SQL `LIKE`-operatoren (of Django's `icontains`-filter). Hoewel deze aanpak computationeel efficiënt is en een hoge recall oplevert, bleek de precisie onvoldoende voor betrouwbare prijsvergelijking.
Een typisch probleem hierbij is het zogenoemde *substring collision*-effect. Zo resulteerde een zoekopdracht naar "ijs" (ice cream) ook in producten zoals "rijst", omdat de substring "ijs" voorkomt in het woord "rijst". Aangezien het systeem initieel de goedkoopste match selecteerde, leidde dit tot incorrecte resultaten waarbij irrelevante producten als beste optie werden voorgesteld. Dit had een negatieve impact op zowel de nauwkeurigheid van de vergelijking als de gebruikerservaring.

4.8.1. Gelaagde similariteitsscore

Om dit probleem te verhelpen werd een aangepaste matching- en rangschikkingslogica ontwikkeld op applicatieniveau. In plaats van een binaire match/no-match-benadering werd een meerlaags scoresysteem geïntroduceerd dat producten rangschikt op basis van hun linguïstische en semantische overeenkomst met de zoekterm.
De matchinglogica bestaat uit drie opeenvolgende lagen, waarbij elke laag een hogere tolerantiegraad heeft maar een lagere prioriteit krijgt in de rangschikking.

Exacte overeenkomst (Laag 0)

De hoogste prioriteit wordt toegekend aan een exacte, hoofdletterongevoelige overeenkomst tussen de productnaam en de zoekterm. Indien beide strings volledig overeenkomen, krijgt het product de laagst mogelijke score (`0.0`). Dit garandeert dat perfecte matches altijd bovenaan de resultaten verschijnen.

Volledig-woordmatching via reguliere expressies (Laag 1)

Indien geen exacte overeenkomst wordt gevonden, controleert het systeem of de zoekterm voorkomt als een afzonderlijk woord binnen de productnaam. Dit wordt gerealiseerd via reguliere expressies met woordgrenzen (`\b`).

Deze aanpak vermijdt substringfouten en onderscheidt bijvoorbeeld correct “ijs” in “vanille ijs” van “rijst”, waar “ijs” slechts deel uitmaakt van een groter woord. Bij meerdere geldige matches wordt een lichte voorkeur gegeven aan kortere productnamen, aangezien deze doorgaans generieker en relevanter zijn.

Fuzzy matching met Levenshtein-afstand (Laag 2)

Als laatste vangnet wordt fuzzy matching toegepast op basis van de Levenshtein-afstand. Dit algoritme berekent het minimale aantal karakterbewerkingen (invoegingen, verwijderingen of vervangingen) dat nodig is om de productnaam om te zetten in de zoekterm.
Om te garanderen dat fuzzy matches altijd lager gerangschikt worden dan exacte of volledig-woordmatches, wordt de afstand verhoogd met een vaste offset. Hierdoor blijven zelfs zeer goede fuzzy matches ondergeschikt aan semantisch sterkere overeenkomsten.

4.8.2. Implementatie

De matchinglogica werd geïmplementeerd binnen de Django-applicatielaag, aangezien dergelijke gelaagde ranking moeilijk efficiënt uit te drukken is in standaard SQL-query’s. Listing 4.6 toont de kern van het scoringsmechanisme.

Listing 4.6: Gelaagde productmatching met prioriteitsscores

```
def score_match(name: str, query: str) -> float:
    name, query = name.lower(), query.lower()

    # Laag 0: exacte match
    if name == query:
        return 0.0

    # Laag 1: volledig woord
    if re.search(rf"\b{re.escape(query)}\b", name):
        # lichte voorkeur voor kortere namen (meer generiek)
        return 1.0 + (len(name) - len(query)) / 100.0

    # Laag 2: fuzzy (Levenshtein)
    return float(levenshtein(name, query) + 2)
```

4.8.3. Impact op systeemfunctionaliteiten

De introductie van het scoresysteem had een directe impact op meerdere onderdelen van de applicatie:

Herordening van zoekresultaten

De zoekpagina haalt nu eerst een beperkte set kandidaatproducten op via `icontains`. Vervolgens wordt voor elk product een similariteitsscore berekend en wor-

den de resultaten gesorteerd op `(score, prijs_per_eenheid)`. Hierdoor verschijnen de meest relevante producten bovenaan, zelfs indien zij niet de absoluut laagste prijs hebben.

Slimme winkelmandberekening

Bij het automatisch samenstellen van een goedkoopste winkelmand wordt niet langer blind het goedkoopste product geselecteerd. In plaats daarvan wordt eerst bepaald welke producten tot de beste matchcategorie behoren. Indien enkel lage-kwaliteit fuzzy matches beschikbaar zijn, wordt dit beschouwd als een lage betrouwbaarheidssituatie en wordt automatisch een nieuwe, gerichte scraping-opdracht ingepland.

4.8.4. Conclusie

Door over te stappen van een eenvoudige substringvergelijking naar een gelaagde similariteitsscore werd het aantal foutieve productmatches aanzienlijk verminderd. De combinatie van volledig-woorddetectie en Levenshtein-afstand biedt een evenwicht tussen strikte nauwkeurigheid en flexibiliteit voor variabele productbenamingen. Deze aanpak verhoogt zowel de betrouwbaarheid van prijsvergelijkingen als de kwaliteit van de gebruikerservaring.

4.9. Geplande updates

Naast gebruikersgestuurde scraping wordt ook proactieve data-verversing voorzien via `scheduler.py`. Dit script publiceert op vaste tijdstippen (dagelijks om 02:00) scraping-opdrachten voor een set basisproducten.
Hierdoor bevat het systeem steeds recente data, zelfs zonder actieve gebruikers.

Listing 4.7: Nightly refresh jobs publiceren in `scheduler.py` (vereenvoudigd)

```
def publish_job(query: str, reason: str):
    payload = {
        "query": query,
        "reason": reason,
        "requested_at": datetime.now(timezone.utc).isoformat(),
    }
    producer.send(TOPIC, key=query.encode("utf-8"), value=payload)

def nightly():
    for term in SEARCH_TERMS:
        publish_job(term, reason="nightly")
    producer.flush()

schedule.every().day.at("02:00").do(nightly)
```

4.10. Docker

Alle componenten van het systeem draaien als afzonderlijke Docker-containers:

- Django webapplicatie
- PostgreSQL databank
- Kafka broker
- Scraper worker
- Normalizer
- Scheduler

Via `docker-compose` worden deze containers samen opgestart en via een gedeeld netwerk met elkaar verbonden.

Listing 4.8: Uittreksel `docker-compose.yaml`: services en Kafka listeners

```
broker:
  image: confluentinc/cp-kafka:7.6.1
  ports:
    - "9092:9092"     # host access
    - "29092:29092"   # container network
  environment:
    KAFKA_LISTENERS: PLAINTEXT_INTERNAL://0.0.0.0:29092,PLAINTEXT_HOST
   ://0.0.0.0:9092
    KAFKA_ADVERTISED_LISTENERS: PLAINTEXT_INTERNAL://broker:29092,
   PLAINTEXT_HOST://localhost:9092

web:
  build: .
  depends_on: [db, broker]
  ports: ["8000:8000"]

scraper-worker:
  build: .
  depends_on: [db, broker]
  command: ["python", "scripts/scraper_worker.py"]
```

Omgevingsvariabelen (zoals databank- en Kafka-configuratie) worden centraal beheerd via een `.env`-bestand.
Deze aanpak garandeert reproduceerbaarheid, vereenvoudigt deployment en maakt horizontale schaalvergroting mogelijk door meerdere workers te starten.

4.11. Conclusie

Het prototype combineert een gebruiksvriendelijke interface met een modulaire en schaalbare backend-architectuur. Door de scheiding tussen scraping, opslag en transformatie sluit het ontwerp nauw aan bij zowel academische literatuur als hedendaagse best practices.
Deze architectuur biedt een solide basis voor verdere uitbreidingen, zoals automatische planning van scrapingtaken, ondersteuning voor bijkomende websites en grootschalige data-analyse.

5

Testen en Resultaten

5.1. Doel van de testfase

Het doel van deze testfase is het evalueren van de effectiviteit van de ontwikkelde prijsvergelijkingsapplicatie. De evaluatie focust op:

- de correctheid van de selectie van de goedkoopste optie (met nadruk op *prijs per eenheid*),
- de relevantie van de gevonden producten (kwaliteit van productmatching),
- de mate waarin het systeem manuele prijsvergelijking kan ondersteunen of vervangen,
- de robuustheid over verschillende productcategorieën (voeding en non-food).

De automatisch gegenereerde resultaten worden vergeleken met een manueel samengestelde referentiewinkelmand die fungeert als *ground truth*. Hierbij wordt expliciet rekening gehouden met het feit dat manuele selectie vaak gestuurd wordt door totale prijs of promoties, terwijl de applicatie primair optimaliseert op prijs per eenheid.

5.2. Methodologie

5.2.1. Referentiewinkelmand (manuele data)

De referentiedata werd manueel verzameld door de auteur op de websites van de winkels (Albert Heijn, Colruyt en Carrefour), zoals een gemiddelde consument dit zou doen. Voor elk product werd:

- het product afzonderlijk opgezocht,
- een representatieve match geselecteerd,

- indien beschikbaar de prijs per eenheid gebruikt,
- anders gesorteerd op laagste totale prijs en vervolgens manueel gecontroleerd op relevantie.

5.2.2. Automatische data (applicatie)

De applicatie verzamelt productinformatie via webscraping en rangschikt resultaten op basis van prijs per eenheid. Hiervoor wordt fuzzy matching toegepast om semantisch minder relevante matches (bv. dierenvoeding bij “kip” of schoonmaakproducten bij “mandarijn”) lager te positioneren. Voor elk item in de winkelmand wordt de goedkoopste optie geselecteerd volgens het gekozen sorteercriterium.

5.2.3. Testset

De methoden werden toegepast op de volgende zeven winkelmanden:

1. melk, boter, kip, brood
2. bananen, ijs
3. mandarijn, pesto, selderij, rigatoni
4. pleister, rijst
5. noedels, mayonaise, kaas
6. wafel, pannenkoek, blauwe bessen
7. maandverband, blush, toiletpapier

5.3. Resultaten

5.3.1. Vergelijking op basis van totale productprijs (“€/product”)

In deze subsectie wordt per winkelmand de totale kost vergeleken tussen: (i) manuele selectie per winkel en (ii) automatische selectie door de applicatie. Dit meet de praktische impact voor een gebruiker die één winkelmand wil samenstellen met minimale *totale* uitgave.

Winkelmand 1: melk, boter, kip en brood

Tabel 5.1: Winkelmand 1: totale productprijs (€/product)

Product	Colruyt	AH	Carrefour	App €/eh	App €/product
Melk	0.75	0.75	0.59	0.69	0.69
Boter	2.09	1.59	0.99	22.80	22.80
Kip	4.19	3.49	2.30	18.19	18.19
Brood	0.89	0.59	0.99	0.99	0.99
Totaal	**7.92**	**6.42**	**4.87**	**42.67**	**42.67**

Winkelmand 2: bananen en ijs

Tabel 5.2: Winkelmand 2: totale productprijs (€/product)

Product	Colruyt	AH	Carrefour	App €/eh	App €/product
Bananen	1.49	0.94	0.99	1.29	1.29
IJs	2.99	1.20	1.49	6.15	6.15
Totaal	**4.48**	**2.14**	**2.48**	**7.44**	**7.44**

Winkelmand 3: mandarijn, pesto, selderij en rigatoni

Tabel 5.3: Winkelmand 3: totale productprijs (€/product)

Product	Colruyt	AH	Carrefour	App €/eh	App €/product
Mandarijn	3.38	2.49	1.75	4.53	4.53
Pesto	1.19	1.19	1.65	7.87	7.87
Selderij	0.99	1.16	1.49	1.49	1.49
Rigatoni	1.93	2.19	1.93	2.20	2.20
Totaal	**7.49**	**7.03**	**6.82**	**16.09**	**16.09**

Winkelmand 4: pleister en rijst

Tabel 5.4: Winkelmand 4: totale productprijs (€/product)

Product	Colruyt	AH	Carrefour	App €/eh	App €/product
Pleister	0.49	0.49	1.29	6.01	6.01
Rijst	1.78	0.69	0.89	3.38	3.38
Totaal	**2.27**	**1.18**	**2.18**	**9.39**	**9.39**

Winkelmand 5: noedels, mayonaise en kaas

Tabel 5.5: Winkelmand 5: totale productprijs (€/product)

Product	Colruyt	AH	Carrefour	App €/eh	App €/product
Noedels	0.89	0.69	0.85	3.29	2.99
Mayonaise	1.15	0.99	1.15	3.99	3.79
Kaas	7.57	0.79	0.79	2.59	2.59
Totaal	**9.61**	**2.47**	**2.79**	**9.87**	**9.37**

Winkelmand 6: wafel, pannenkoek en blauwe bessen

Tabel 5.6: Winkelmand 6: totale productprijs (€/product)

Product	Colruyt	AH	Carrefour	App €/eh	App €/product
Wafel	1.29	1.19	0.37	3.86	3.86
Pannenkoek	1.79	1.79	1.85	1.79	1.79
Blauwe bessen	2.69	2.99	4.99	2.69	2.69
Totaal	**5.77**	**5.97**	**7.21**	**8.34**	**8.34**

Winkelmand 7: maandverband, blush en toiletpapier

Tabel 5.7: Winkelmand 7: totale productprijs (€/product)

Product	Colruyt	AH	Carrefour	App €/eh	App €/product
Maandverband	0.88	0.69	0.95	1.90	1.90
Blush	2.99	—*	2.69	3.49	3.49
Toiletpapier	3.87	2.99	2.39	2.36	2.36
Totaal	**7.74**	**3.68**	**6.03**	**7.75**	**7.75**

* Albert Heijn bevat geen blush in het assortiment voor deze test.

Observatie.
De applicatie is in meerdere winkelmanden duurder dan de goedkoopste manuele winkel. Dit kan verklaard worden door (i) semantische mismatches bij bepaalde zoektermen en (ii) het feit dat de applicatie optimaliseert op prijs per eenheid, terwijl de manuele selectie vaak gestuurd is door laagste totale prijs of promoties. Dit onderstreept het belang van expliciete optimalisatiecriteria in automatische prijsvergelijkingssystemen.

5.3.2. Financiële evaluatie: bespaart de applicatie geld?

Om het effect voor de gebruiker te kwantificeren, wordt per winkelmand de apptotaalkost vergeleken met de *laagste* manuele kost (minimum over de drie winkels). De besparing is gedefinieerd als:

$$\text{besparing} = \min(\text{manueel}) - \text{app}.$$

Positief betekent goedkoper met de app; negatief betekent duurder.

Tabel 5.8: Besparing t.o.v. goedkoopste manuele winkel (€/product)

Winkelmand	Goedkoopste manueel	App	Besparing
1	4.87	42.67	-37.80
2	2.14	7.44	-5.30
3	6.82	16.09	-9.27
4	1.18	9.39	-8.21
5	2.47	9.37	-6.90
6	5.77	8.34	-2.57
7	3.68	7.75	-4.07

Interpretatie.
Op basis van deze dataset is de applicatie in absolute aankoopkost niet goedkoper dan de goedkoopste manuele winkel. Dit resultaat is consistent met het feit dat de applicatie primair optimaliseert op prijs per eenheid en gevoelig blijft voor semantische mismatches. Tegelijk blijft het voordeel van de applicatie wél duidelijk in tijdswinst en gebruiksgemak (zie Sectie 5.4.3).

5.3.3. Zoekpagina als alternatief bij twijfelgevallen

Bij twijfel kan de *Zoek*-pagina worden gebruikt om meerdere alternatieven te bekijken (topresultaten beperkt tot 100 rijen) en zo manueel een voorkeur te maken.

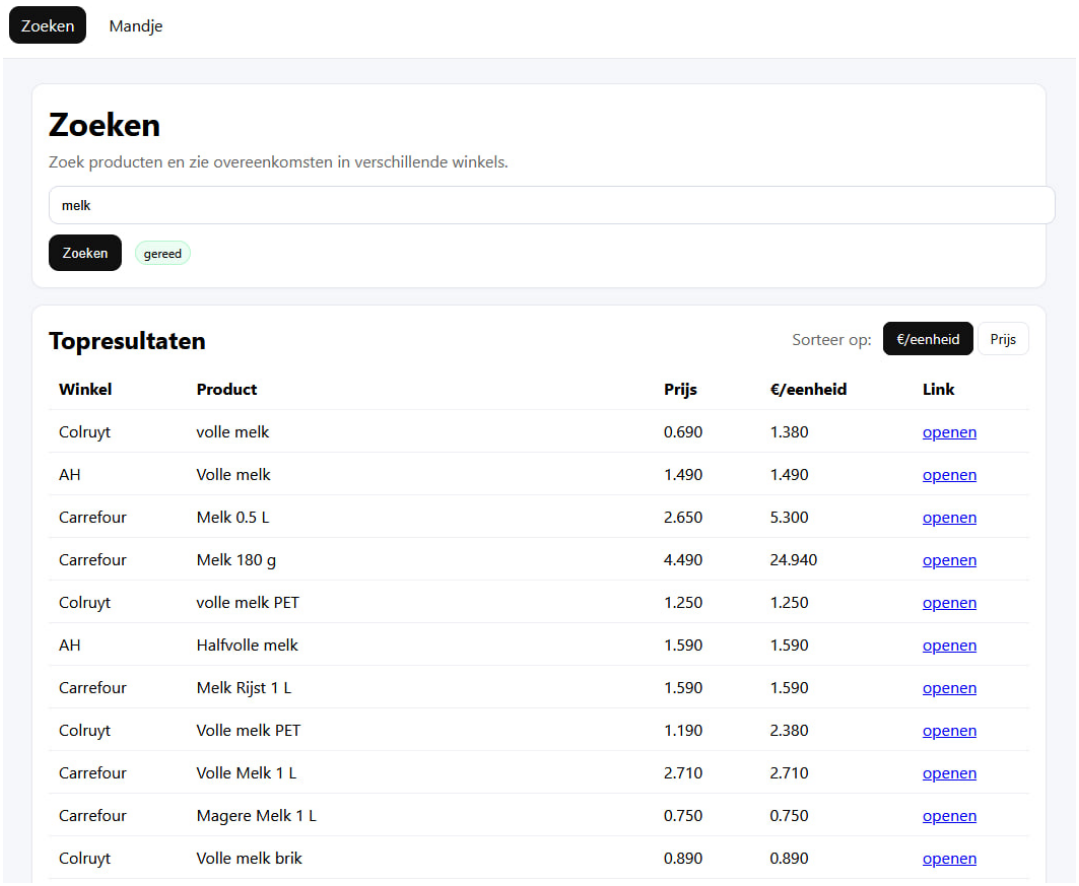

Figuur 5.1: Schermafbeelding van de Django-app met zoekopdracht “melk”

5.4. Grafische analyse

5.4.1. Goedkoopste manueel vs. applicatie (€/product)

Figuur 5.2 toont per winkelmand de goedkoopste manuele kost (minimum over winkels) tegenover de totale kost van de applicatie.

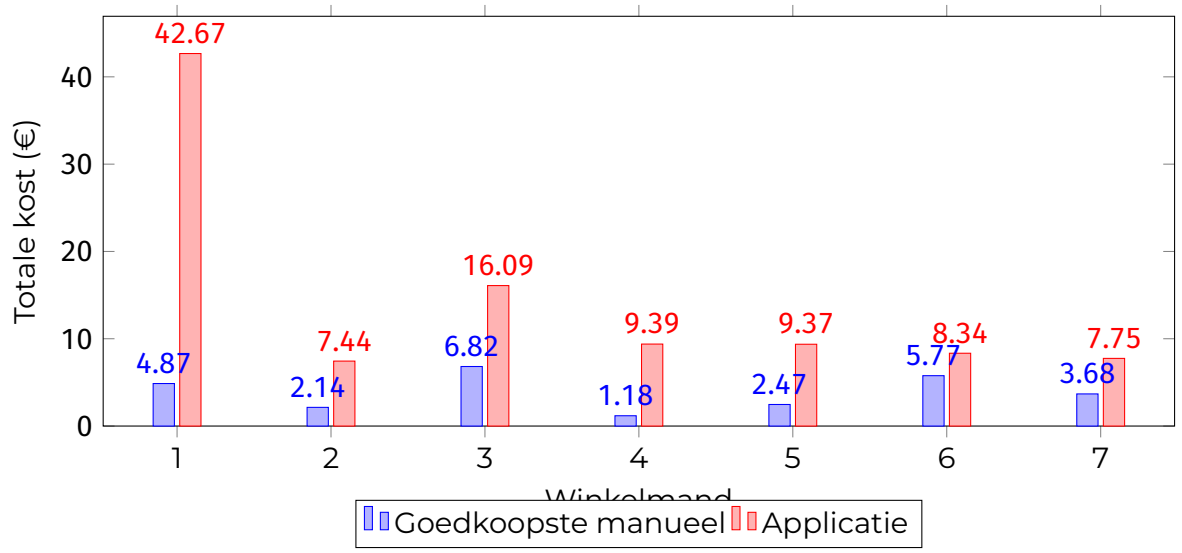

Figuur 5.2: Vergelijking totale kost: goedkoopste manuele winkel vs. applicatie (€/product)

5.4.2. Besparing per winkelmand

Figuur 5.3 visualiseert de besparing zoals gedefinieerd in Tabel **??**. Negatieve waarden duiden op een meerkost voor de applicatie.

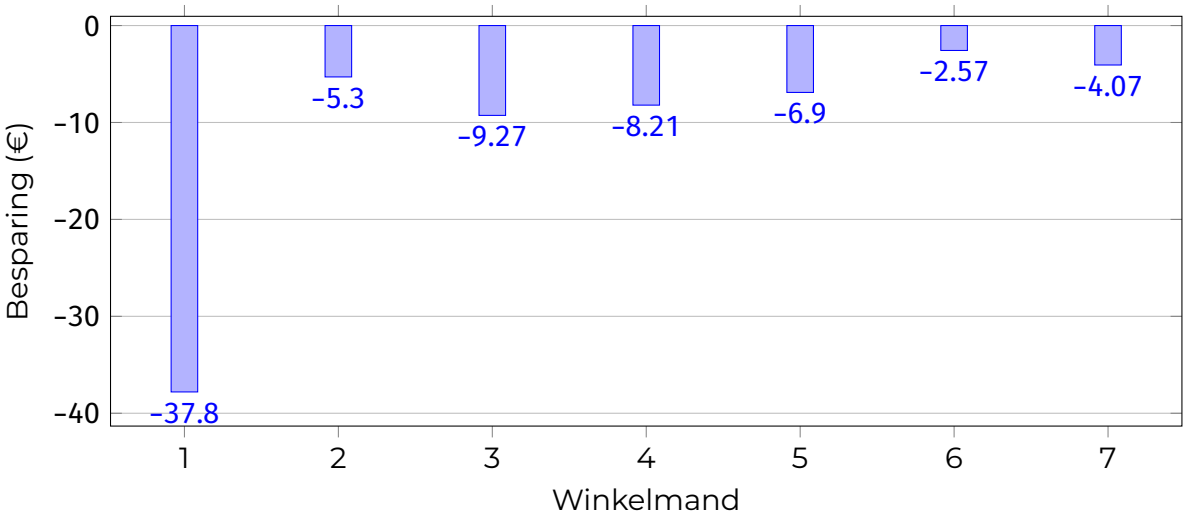

Figuur 5.3: Besparing t.o.v. goedkoopste manuele winkel (negatief = applicatie duurder)

5.4.3. Tijdsbesparing

Tabel 5.9: Vergelijking tijdsinvestering

Methode	Gemiddelde tijd
Manuele vergelijking	15–25 minuten
Applicatie	< 1 minuut

De applicatie reduceert de benodigde tijd met meer dan 90% ten opzichte van manuele vergelijking, doordat zoeken, filteren, en het interpreteren van prijs per eenheid geautomatiseerd worden.

5.5. Conclusie

De testresultaten tonen dat de applicatie een sterke meerwaarde biedt op het vlak van snelheid en gebruiksgemak. In deze dataset blijkt de applicatie echter niet goedkoper te zijn dan de goedkoopste manuele winkel in absolute aankoopkost. Dit wijst erop dat de huidige implementatie in sterke mate beïnvloed wordt door semantische mismatches en de keuze van het optimalisatiecriterium (prijs per eenheid versus totale prijs).
Als proof-of-concept bevestigt dit hoofdstuk de technische haalbaarheid en de praktische winst in tijd, en tegelijkertijd duidelijke verbeterpunten aantoont: expliciete productcategorieën, betere semantische filtering, en eventueel een tweede optimalisatiemodus gericht op *laagste totale kost* zijn een must.

6

Beperkingen en Toekomstig Werk

Hoewel het ontwikkelde prijsvergelijkingssysteem functioneel en architecturaal robuust is, zijn er verschillende beperkingen die voortkomen uit de scope van het project, de beschikbare data en de gekozen technieken.

6.1. Beperkingen van de huidige implementatie

6.1.1. Productnormalisatie en eenheidsvergelijking

Hoewel het systeem prijzen per eenheid opslaat (bijvoorbeeld prijs per kilogram of liter), is de normalisatie van eenheden momenteel beperkt tot de informatie die expliciet door de retailers wordt aangeleverd. Producten met verschillende verpakkingsgroottes of afwijkende eenheden (bijvoorbeeld stuks versus gewicht) worden niet automatisch naar een gemeenschappelijke maat omgerekend. Het wordt nu aangenomen dat alle winkels dezelfde eenheid gebruiken.
Dit betekent dat sommige vergelijkingen enkel correct zijn indien alle retailers consistente eenheidsinformatie aanbieden. Volledige automatische eenheidsconversie (bijvoorbeeld ml naar liter of gram naar kilogram) zou extra semantische interpretatie vereisen en valt buiten de huidige scope.

6.1.2. Product- en merkdeduplicatie

Het huidige datamodel behandelt producten primair op basis van hun naam. Hoewel dit in combinatie met het gelaagde matching-algoritme in de meeste gevallen correcte resultaten oplevert, bestaat het risico dat identieke producten met licht verschillende benamingen (bijvoorbeeld door merk- of taalvariaties) als aparte producten worden opgeslagen of minder goed scoren behalen in het Levenshtein-algoritme.

6.1.3. Beperkingen van scraping en anti-botmaatregelen

De betrouwbaarheid van scraping blijft inherent afhankelijk van de stabiliteit en toegankelijkheid van externe websites. Wijzigingen in HTML-structuren, GraphQL-schema's of anti-botmaatregelen kunnen ertoe leiden dat spiders tijdelijk falen.
Hoewel het systeem hier architecturaal op voorbereid is (door ontkoppeling via Kafka en foutisolatie), vereist structurele breuk altijd manuele aanpassing van de betrokken spider.

6.1.4. Latency en eventual consistency

Door het gebruik van asynchrone verwerking en achtergrondtaken is het systeem gebaseerd op het principe van *eventual consistency*. Dit betekent dat gebruikers bij een eerste zoekopdracht mogelijk tijdelijk verouderde resultaten zien, terwijl nieuwe data op de achtergrond wordt opgehaald.
Hoewel deze aanpak noodzakelijk is om de gebruikersinterface responsief te houden, introduceert ze een beperkte vertraging tussen data-acquisitie en presentatie.

6.2. Toekomstige uitbreidingen

6.2.1. Geavanceerde productmatching met machine learning

Het huidige matching-algoritme is gebaseerd op linguïstische heuristieken en Levenshtein-afstanden. Een mogelijke uitbreiding bestaat uit het toepassen van machine learning-technieken, zoals word embeddings of transformer-gebaseerde taalmodellen, om semantische gelijkenis tussen productnamen beter te capteren.
Dit zou vooral nuttig zijn voor meertalige productnamen en complexere beschrijvingen, maar vereist een voldoende grote en gelabelde dataset.

6.2.2. Historische prijsanalyse en trends

Momenteel bewaart het systeem enkel de meest recente prijs per product en winkel. Door historische prijsgegevens te archiveren, zou het mogelijk worden om prijsfluctuaties te analyseren, trends te visualiseren en gebruikers te informeren over tijdelijke promoties of prijsdalingen.
Dit zou tevens de basis vormen voor voorspellende analyses en geavanceerde gebruikersfunctionaliteiten.

6.2.3. Uitbreiding naar extra retailers

De modulaire scraping-architectuur laat toe om eenvoudig nieuwe retailers toe te voegen door het ontwikkelen van bijkomende spiders. Toekomstig werk kan zich richten op het uitbreiden van het systeem naar andere supermarkten of e-commerceplatformen, mits respect voor hun gebruiksvoorwaarden.

6.2.4. Verbeterde caching- en invalidatiestrategieën

Hoewel het systeem reeds gebruikmaakt van tijdsgebaseerde verversing (stale-after beleid), kan dit verfijnd worden met meer geavanceerde cachingstrategieën. Bijvoorbeeld door prijsgevoelige producten frequenter te verversen of door gebruikersgedrag mee te nemen in de prioritering van scraping-opdrachten.

6.2.5. Schaalvergroting en distributie

Dankzij de containergebaseerde architectuur kan het systeem horizontaal opgeschaald worden door meerdere scraper workers te deployen. Toekomstig werk kan zich richten op load balancing, dynamische worker-scaling en monitoring van scrapingprestaties in een gedistribueerde omgeving.

6.3. Slotbeschouwing

Dit project toont aan dat een schaalbaar en robuust prijsvergelijkingssysteem gerealiseerd kan worden door het combineren van web scraping, event-driven architectuur en containerisatie. De besproken beperkingen vormen geen fundamentele tekortkomingen, maar illustreren de complexiteit van real-world data-integratie.
De voorgestelde uitbreidingen bieden een duidelijke roadmap voor verdere verfijning en commercialisatie van het systeem en onderstrepen de praktische relevantie van de gekozen architecturale aanpak.

7

Conclusie

Dit onderzoek startte vanuit de onderzoeksvraag: **“Hoe kan een transparant en schaalbaar systeem worden ontworpen en ontwikkeld om automatisch supermarktprijzen in België te verzamelen, te matchen en te vergelijken, met gebruik van een semantisch matchingsysteem?”**
De resultaten tonen aan dat het technisch haalbaar is om met een Scrapy-gebaseerde scrapingpipeline op een relatief betrouwbare manier prijsinformatie te verzamelen uit heterogene bronnen. Door Apache Kafka te gebruiken als asynchrone berichtlaag worden de verschillende systeemonderdelen (gebruikersinterface, scraping, normalisatie en opslag) logisch ontkoppeld. Deze scheiding verhoogt de stabiliteit en maakt het mogelijk om de oplossing schaalbaar en fouttolerant op te zetten: falende of trage scrapingprocessen blokkeren de gebruikersinterface niet, en verwerking kan desgewenst horizontaal opgeschaald worden via meerdere workers.
Daarnaast blijkt uit de uitgevoerde winkelmandtesten dat het systeem de gebruiker tijd kan besparen in vergelijking met manuele prijsvergelijking. Vooral bij herhaalde zoekopdrachten en grotere winkelmanden wordt de meerwaarde zichtbaar, doordat de applicatie automatisch resultaten verzamelt, structureert en presenteert.
Tegelijkertijd werd een belangrijke beperking blootgelegd: een semantische matchingaanpak die voornamelijk steunt op producttitels is op zichzelf onvoldoende om consequent de goedkoopste optie te selecteren. Productnamen zijn sterk afhankelijk van de retailer en bevatten vaak variaties, marketingtermen en ongenormaliseerde beschrijvingen. De gebruiker daarentegen focust in de praktijk eerder op prijs en alleen dan op exacte titelovereenkomsten. Hierdoor ontstaat een spanningsveld tussen “beste match” en “laagste prijs”: de meest relevante match is niet noodzakelijk de goedkoopste beschikbare optie.
Om deze discrepantie te beperken werd binnen de applicatie gekozen voor een compromisstrategie, waarbij producten eerst worden gerangschikt op basis van

matchkwaliteit (o.a. exacte overeenkomst, volledig-woorddetectie en fuzzy matching) en vervolgens op prijscriteria. Deze aanpak verhoogt de betrouwbaarheid van de getoonde resultaten en reduceert foutieve matches, maar kan ertoe leiden dat een minimaal goedkopere, minder relevante optie lager in de ranking verschijnt.
Samenvattend bewijst dit project dat een geautomatiseerde prijsvergelijker met een event-driven architectuur technisch haalbaar is en duidelijke gebruikswaarde heeft, vooral als tijdsbesparend hulpmiddel. Verdere vooruitgang hangt echter sterk af van verbeterde productnormalisatie en rijkere identificatoren (bv. EAN/GTIN, verpakkingsgrootte, vaste producttaxonomie) of meer geavanceerde semantische modellen die beter rekening houden met context. Hierdoor kan in toekomstig werk de kloof tussen “relevantie” en “prijsoptimalisatie” verder worden verkleind en kan het systeem niet enkel tijdsbesparing bieden, maar ook betrouwbaarder prijsvoordeel maximaliseren.

A

Onderzoeksvoorstel

Het onderwerp van deze bachelorproef is gebaseerd op een onderzoeksvoorstel dat vooraf werd beoordeeld door de promotor. Dat voorstel is opgenomen in deze bijlage.

A.1. Introduction

In recent years, food prices in Belgium have risen significantly, placing increasing financial pressure on students and other budget-conscious consumers. While several supermarket price comparison tools exist, they generally focus on presenting the lowest prices without considering practical limitations, such as the distance a consumer is willing to travel or the number of stores they can reasonably visit. As a result, these tools provide theoretically optimal solutions that are difficult to implement in real-world scenarios, particularly for students with limited mobility and tight schedules.
Students frequently face challenges in identifying the most cost-effective shopping options. Limited budgets, combined with time and travel constraints, complicate efficient price comparisons across different supermarkets. Existing tools rarely incorporate these constraints, creating a gap between available price information and actionable, user-centered insights. This research addresses this gap by focusing on the development of a system tailored to the needs of students in Ghent.

To develop such a system, the following main research question needs to be answered: How to design and develop a transparent and scalable system, capable of automatically collecting, matching, and comparing supermarket prices in Ghent, that takes into account consumers' distance and limits the amount of shops visited?
To support answering this question and guide the research, an improved understanding of the target audience and the problem context is required. More specifi-

cally:

- What factors currently influence students' consumption habits in Belgium?
- What kind of tools for price comparisons are available in Belgium, and what shortcomings do they have for students?
- What technical and practical challenges are there for collecting price data from Belgian supermarkets?

Furthermore, research into programmatic and architectural details of the candidate solution, and its success factors, needs to be conducted. More precisely:

- How can supermarket price data be automatically collected and structured?
- What approaches can be used to match general product names to achieve accurate comparisons?
- How can the system calculate and recommend the most cost-effective combinations of stores within a user-defined distance and a store limit?
- How can the system architecture be designed to support scalability and transparency of the data?
- What criteria must the prototype meet in order to be considered a valid proof-of-concept?

The result of this research is a prototype, implemented using Python and Django, that collects price data through web scraping from Belgian supermarket websites. Users of this prototype will be able to input a general shopping list and specify a maximum travel distance or a limit on the number of stores. The system will then calculate the most cost-effective combination of stores based on these constraints. The system will be evaluated using a predefined "student shopping cart" to compare the total cost of shopping at a single store versus the optimized multi-store recommendation generated by the system.

This research contributes to the development of a realistic and accessible supermarket price comparison tools that integrate technical efficiency with consumer-centered constraints. By focusing on students' needs, the system aims to enhance price transparency and support informed, budget-conscious shopping decisions, offering practical insights that could inform future consumer-oriented applications.

A.2. Literature Review

A.2.1. Context: food prices and student pressure

Recent Belgian indicators show persistent price pressure on food. According to Statbel's CPI' report, the headline and core inflation remain elevated throughout

2024-2025, with core inflation above 2% in October 2025(Statbel, 2025a, 2025b). Independent tracking by Testaankoop/Testachats likewise reports supermarket specific inflation
around 4% in 2025 (Testaankoop, 2025a, 2025b). Broader macro assessments (*OECD Economic Surveys: Belgium 2024*, 2024) show the detailed impact of inflation, confirming price pressure on consumers. Together, these sources substantiate the problem relevance for the price-sensitive groups such as students.

A.2.2. Existing solutions

There are several Belgian specific tools available to help consumers compare supermarket prices and select better products such as PingPrice (PingPrice, 2024) and G4U (G4U, 2025). However, both apps have their limitations. PingPrice compares products using barcodes, which prevents it from effectively comparing store-brand or generic products that lack standardized identifiers. As a result, many relevant items are excluded from comparisons.
G4U, on the other hand, offers extensive product and promotion information, but operates as a paid service, limiting its accessibility for students who already face financial constraints. Consequently, there is a need for a free and transparent alternative that allows users to compare generic product categories, rather than barcodes.

A.2.3. Supermarket data: web scraping as a practical pipeline

Because Belgian retailers rarely expose APIs for product/price feeds to the public, web scraping is a pragmatic way of obtaining structured price data from public pages. While (Logos et al., 2023) and (Brown et al., 2024) guide through ethical and methodological approach to web scraping, they do not propose specific technical implementation for cases where public APIs are not available.
Building on their recommendations, the following process is proposed in this paper: HTML retrieval, parsing of the content, automated browser rendering for JavaScript-dependent content, and storing the price data. This approach to Belgian specific market is inspired by Statbel (Ken Van Loon, 2018) paper.

A.2.4. Legal and Ethical considerations for scraping

Scraping must respect terms of service (ToS), IP, and data-protection constraints. Comparative analyses of website ToS show many platforms explicitly regulate ”robots/scrapers”, requiring researchers to weigh necessity, proportionality, and compliance mechanisms (Fiesler et al., 2020). Recent overviews propose concrete checklists on legality, ethics, and institutional review: for example, documenting purpose, rate limits, storage, data sharing (Brown et al., 2024; Logos et al., 2023). These frameworks guide the governance of the prototype.

A.2.5. Product matching across retailers

Price comparison requires aligning "the same" item across stores despite naming/pack size differences. Literature supports a two-stage approach: 1. exact identifiers (e.g., EAN/GTIN) where available; 2. approximate/semantic matching using fuzzy similarity (Levehnstein/TF-IDF/cosine) or ML embeddings for near-duplicate detection (Kerek, 2020; Ning et al., 2022). These methods map directly from user-supplied product name to store's specific unit.

A.2.6. Decision support, trust, and constraints in grocery apps

Trust is a critical factor influencing user's willingness to adopt digital grocery tools. (Chakraborty et al., 2024) highlights the importance of information credibility, clarity and quality of interaction for building user's trust in online grocery environments. Building on this perspective, (DeZao, 2024) emphasizes trust in AI-powered systems. By showing their data sources and timestamps, these systems become more transparent and consequently are perceived as more reliable and fair by users. Moreover, real-world constraints such as travel distance and ability to visit certain amount of stores affect the usefulness of such tools. Integration of these constraints expands and improves decision support criteria.
In summary, the literature supports a pipeline combining web scraping, reproducible matching (EAN-first + fuzzy/ML fallback), and transparent interfaces that expose source and recency, evaluated on precision/recall for matches and realistic student-centric constraints (e.g. distance, maximum amount of stores) for cost outcomes.

A.3. Methodology

This thesis focuses on the design and implementation of a functional prototype that automatically collects, matches, and compares supermarket prices in Ghent. The research process is divided into five main phases: system design, data collection, data processing and product matching, system implementation and evaluation.

A.3.1. System Design

In the first phase, the system's architecture and data flow were defined to ensure modularity, scalability, and transparency. The architecture consists of three distinct layers. The first layer is called the data layer and manages the storage of product and price information in a PostgreSQL relational database. The second layer is the processing layer and handles web scraping, data cleaning, and product matching logic, implemented in Python. The third layer is the presentation layer, which provides a user interface through a Django web application, allowing users to input shopping lists and define constraints such as travel distance and the number of stores. These design choices were made to support future scalability and the integration of new supermarket and product data.

A.3.2. Data Collection

The data collection phase focuses on gathering daily product and price information from selected Ghent supermarkets. This is achieved using web scraping techniques, using Python libraries such as Requests, BeautifulSoup, and Selenium. Requests is used to send HTTP requests and retrieve the raw HTML content of web pages, giving access to publicly available information without a browser. BeautifulSoup is employed to parse and extract specific elements from the HTML content obtained through Requests. Lastly, Selenium is used for scraping dynamic websites that load data through JavaScript after initial page request.
Each scraper retrieves product names and prices. All data is stored along with additional metadata such as timestamps and data sources to maintain transparency and traceability.

A.3.3. Data Processing and Product Matching

Since supermarkets use different product names and formats, the collected data requires preprocessing before comparison. This phase happens in a number of steps: data cleaning, normalization and product matching. The data cleaning step includes the removal of duplicates and unit normalization (e.g. price per kg or per liter). The matching step implements string similarity algorithms, such as Levehnstein distance and cosine similarity on TF-IDF vectors, to match equivalent products across stores. The filtering step stores the closest product matches to ensure accuracy in comparisons. The result of this phase is a unified dataset where identical or similar products from different stores can be compared directly.

A.3.4. System implementation

The tool integrates following components into a single Django-based web application. Data Scraper runs scheduled scraping jobs and updates the database. Data Processor performs data cleaning and product matching. Comparison Engine calculates the most cost-effective store combinations based on user's constraints. User Interface allows users to input shopping lists and define parameters such as maximum distance and store count. The system is designed for local deployment during testing but can be extended for public use.

A.3.5. Evaluation

The evaluation phase assesses the practical usefulness of the system, using predefined student shopping carts that simulate realistic purchase scenarios. Each cart is analyzed from two perspectives: Single-store shopping (purchasing all items in one supermarket) and Optimized multi-store shopping (purchasing all items using the system's recommendation).
Based on these results, the prototype can be considered a successful proof-of-concept if it is capable of producing cost reductions for Ghent students with various criteria,

while maintaining transparency in its decision process.

A.4. Expected results

The main expected outcome of this research is a functional prototype that demonstrates the feasibility of a system for collecting, matching and comparing product prices. This includes a working scraping module that collects price and data from multiple stores' websites, and a matching module for corresponding items across different shops with a high level of accuracy. After evaluation using predefined student carts, the prototype is expected to demonstrate measurable price difference when compared to shopping in a single supermarket. These results should confirm added value of the system in terms of affordability.

Bibliografie

Almeida, J., & Silva, R. (2020). API-Based Data Extraction for Scalable Web Data Collection. *Journal of Web Engineering*, *19*(3), 245–262.

Brown, M. A., Gruen, A., Maldoff, G., Messing, S., Sanderson, Z., & Zimmer, M. (2024). Web Scraping for Research: Legal, Ethical, Institutional, and Scientific Considerations. https://doi.org/10.48550/ARXIV.2410.23432

Chakraborty, D., Kumar Kar, A., Patre, S., & Gupta, S. (2024). Enhancing trust in online grocery shopping through generative AI chatbots. *Journal of Business Research*, *180*, 114737. https://doi.org/10.1016/j.jbusres.2024.114737

Data Journal. (2024, 26 augustus). *JavaScript vs. Python for Web Scraping*. https://medium.com/@datajournal/javascript-vs-python-for-web-scraping-dee9102e56cf

DeZao, T. (2024). Enhancing transparency in AI-powered customer engagement. *Journal of AI, Robotics & Workplace Automation Volume 3 Number 2,2024*. https://doi.org/10.48550/ARXIV.2410.01809

Eyzenakh, D., Rameykov, A., & Nikiforov, I. (2021). High Performance Distributed Web Scraper. *Proceedings of the Institute for System Programming of the RAS*, *33*(3), 87–100. https://doi.org/10.15514/ispras-2021-33(3)-7

Fiesler, C., Beard, N., & Keegan, B. C. (2020). No Robots, Spiders, or Scrapers: Legal and Ethical Regulation of Data Collection Methods in Social Media Terms of Service. *Proceedings of the International AAAI Conference on Web and Social Media*, *14*, 187–196. https://doi.org/10.1609/icwsm.v14i1.7290

G4U. (2025). G4U. https://g4u-app.com/

Ken Van Loon, D. R. (2018). Webscraping, de verzameling en verwerking van online data voor de consumptieprijsindex. https://statbel.fgov.be/sites/default/files/files/documents/Analyse/NL/webscraping_nl.pdf

Kerek, H. (2020). *Product Similarity Matching for Food Retail using Machine Learning* (**publication**Nr. 2020:067) [masterscriptie, KTH, Mathematical Statistics].

Laender, A. H. F., Ribeiro-Neto, B. A., da Silva, A. S., & Teixeira, J. S. (2002). A Brief Survey of Web Data Extraction Tools. *ACM SIGMOD Record*, *31*(2), 84–93. https://doi.org/10.1145/565117.565137

Li, H., & Kumar, S. (2022). Scraping Dynamically Rendered Web Content: Challenges and Solutions. *ACM Computing Surveys*, *54*(6), 1–28.

Logos, K., Brewer, R., Langos, C., & Westlake, B. (2023). Establishing a framework for the ethical and legal use of web scrapers by cybercrime and cybersecurity

researchers: learnings from a systematic review of Australian research. *International Journal of Law and Information Technology*, *31*(3), 186–212. https://doi.org/10.1093/ijlit/eaad023

Majebi, I. (2025, 18 maart). *Best Practices for Web Scraping in 2025*. https://www.scraperapi.com/web-scraping/best-practices/

Mitchell, R. (2018). *Web Scraping with Python*. OŔeilly Media.

Ning, W., Cheng, R., Shen, J., Haldar, N. A. H., Kao, B., Yan, X., Huo, N., Lam, W. K., Li, T., & Tang, B. (2022). Automatic Meta-Path Discovery for Effective Graph-Based Recommendation. *Proceedings of the 31st ACM International Conference on Information & Knowledge Management*, 1563–1572. https://doi.org/10.1145/3511808.3557244

OECD Economic Surveys: Belgium 2024. (2024, september). OECD Publishing. https://doi.org/10.1787/c671124e-en

Olston, C., & Najork, M. (2010). Web Crawling and Scraping: Techniques and Challenges. *Foundations and Trends in Information Retrieval*, *4*(3), 175–246.

PingPrice. (2024). PingPrice. https://www.pingprice.be/en/

Scrapy Developers. (z.d.). *Scrapy Documentation*. https://docs.scrapy.org/en/latest/

Sibiryakov, A. (2015, 6 augustus). *Distributed Frontera: Web Crawling at Scale*. https://www.zyte.com/blog/distributed-frontera-web-crawling-at-large-scale

Statbel. (2025a). Harmonised index of consumer prices - December 2024. https://statbel.fgov.be/en/news/harmonised-index-consumer-prices-december-2024

Statbel. (2025b). Consumer price index - September 2025. https://statbel.fgov.be/en/themes/consumer-prices/consumer-price-index

Testaankoop. (2025a). Rundsvlees wordt duur: biefstuk 18% duurder dan vorig jaar, americain natuur 17% duurder. https://www.test-aankoop.be/familie-prive/supermarkten/pers/inflatie-april-2025

Testaankoop. (2025b). Inflatie in de supermarkt: net onder 4 % in september. *Helena Coupette*. https://www.test-aankoop.be/familie-prive/supermarkten/nieuws/maandelijkse-inflatie-supermarkt

Westera, J. (z.d.). *Albert Heijn GraphQL API*. https://github.com/JaapWestera/albert-heijn-graphql-api

Zhao, Y., & Zhang, L. (2021). Detection and Mitigation of Automated Web Scraping. *IEEE Internet Computing*, *25*(4), 34–42.